

從 SNP Array 到 WES/WGS：基因體資料分析入門

講師: OO 醫院精準醫學核心實驗室組長邱 XX

本教材適合臨床醫師、臨床工作者及初次接觸基因體資料分析的研究人員。你不需要預先具備程式設計經驗；閱讀時可先理解資料與分析結果，再依指令完成練習。

這堂課將帶你沿著兩條路徑認識基因體分析：一條從 SNP array 的探針訊號走到基因型與區域分析，另一條從定序讀段走到比對檔與變異。重點是理解資料如何產生、分析方法依賴哪些假設，以及結果是否有足夠證據支持，而不是個別變異的致病性分類或檢測報告解讀。所有操作使用合成資料，不包含病人資訊，也不能用來驗證臨床檢測效能。

教材使用方式

你可以依序閱讀概念、操作練習及結果解析。第一次接觸指令時，不必記住所有參數；先確認每一步讀入什麼、產生什麼，以及輸出能回答哪個問題。若想跟著操作，請先完成附錄 A 的安裝；暫時無法安裝，也可以利用文中的結果表完成判讀練習。

主題	你將學會什麼
一、研究問題與平台選擇	選平台並說明需要保留的資料
二、技術與資料格式	辨認訊號、基因型、比對與變異檔
三、Array 分析與 QC	解釋 missingness、HWE、親緣與 PCA
四、Array 實作與情境練習	找出一個樣本問題與一個位點問題
五、WES/WGS 分析	串接 FASTQ、BAM、VCF 與 QC
六、整合判讀與區域分析	區分 ROH、CNV 與序列變異證據
七、自我檢核與研究應用	檢查理解程度，整理自己的分析需求

完成後，你應能選擇適合研究問題的技術、描述兩條資料流程、讀懂基本檔案與 QC 指標，並知道何時應暫停下游推論、回到原始證據。

閱讀與操作時，建議在筆記中保留三欄：「我的觀察」、「支持這項觀察的檔案或數值」、「還需要確認的資訊」。這能幫助你區分已知事實與待驗證的推論。

一、由研究問題選擇資料平台

1.1 研究案例：一份檢體能回答哪些問題？

研究團隊有一組心血管疾病病例與對照，希望回答：「常見變異是否與疾病相關？樣本是否存在重複或親緣關係？是否有罕見編碼變異？是否出現較大的拷貝數改變？」

這四個問題需要的測量方式、解析度、樣本數及統計方法不同。選擇平台前，你需要先確定想找的是哪一類變異，或想檢查哪一種資料特性。採用涵蓋範圍最大的技術，也不等於自動回答所有問題。

平台	測量方式	適合切入的問題	重要限制
SNP array (單核苷酸多型性晶片)	探針測量預設位點的等位基因訊號	常見變異、族群結構、親緣、ROH；有強度資訊時可分析部分 CNV	受探針位置、密度與設計族群影響，不能全面找新序列變異
Panel (目標基因套組)	定序選定基因或區域	聚焦特定基因集合的研究	未涵蓋區域通常無法評估，版本間目標區不同
WES (全外顯子定序)	捕捉並定序外顯子等設計目標	編碼區 SNV、小型 indel 等	捕捉效率不均，非編碼區與部分外顯子仍可能不足
WGS (全基因體定序)	不以外顯子捕捉限制定序範圍	更廣的序列變異、部分 CNV/SV 分析	重複序列與複雜區域仍困難；不同變異需要不同演算法

SNV 是單一鹼基的序列差異；SNP 通常指族群中的單核苷酸多型性，實務用語未必嚴格區分頻率。Indel 是短片段插入或缺失；CNV 是一段 DNA 的拷貝數變化；SV 是較大型的結構變異，例如倒位或易位。不要把所有變異都當成同一種 caller 可以解決。

1.2 練習：為問題選擇資料

請先不看解析，為以下需求各選一個資料來源，並寫下選擇理由：

1. 比較病例與對照的常見 SNP。
2. 尋找罕見的編碼區變異。
3. 探索非編碼區的序列變異。
4. 確認兩份資料是否可能來自同一個人。

參考解析：可分別從 array、WES、WGS、既有高品質 genotype 資料切入。這不是唯一答案；還要考慮目標區域的覆蓋、成本、樣本數與既有資料。例如，檢查重複樣本未必需要重新定序，既有且足夠的高品質 genotype 可能已能提供線索。

本節重點：面對分析結果，先問「它來自什麼訊號、經過哪些假設算出來」，再判斷它能回答什麼問題。

二、從測量訊號到檔案

2.1 SNP array：連續訊號變成離散基因型

Probe（探針）是設計用來辨識特定位置的短序列。儀器取得 fluorescence intensity（螢光強度），再經背景處理與 normalization（正規化），減少技術尺度差異。Genotype calling 依兩種等位基因訊號的群聚位置，推估 AA、AB、BB 或無法判定。

平台原始訊號（例如 IDAT 或 CEL；依廠牌 / 晶片而異）

- 背景處理、正規化、使用適當 manifest / cluster reference
- genotype calls + 品質分數 + 強度衍生資訊
- 樣本與位點 QC
 - └ genotype → PLINK → PCA、親緣、ROH 等
 - └ intensity / BAF / LRR → 區域分段與 CNV 評估

Manifest 是探針身分、位置及設計資訊；cluster reference 是用來判定基因型群聚的參考。不同平台不可任意混用。PLINK 不會直接把所有 IDAT/CEL 轉成可靠 genotype；原始訊號處理需要相容的平台流程。

Hard call 是把不確定性壓縮成 AA / AB / BB 等單一判定。沒有被保留下來的強度資訊，不能單靠 hard call 完整還原。

2.2 定序：讀段變成比對與變異

FASTQ（讀段及鹼基品質）

- read QC → alignment（對到參考基因體）
- BAM / CRAM（比對位置及證據）
- variant calling（估計基因型與變異）
- VCF / BCF → filtering、annotation、cohort analysis

Reference genome（參考基因體）是共同座標與序列基準，不代表每個人的正常或健康基因體。GRCh37 與 GRCh38 座標不能直接混用；即使版本名稱相同，也需確認 contig、decoy、FASTA 內容及索引一致。

2.3 常見檔案速查

檔案	存什麼	第一眼要檢查什麼
IDAT / CEL	平台相關的原始晶片訊號	晶片型號、樣本對照表與處理版本
PED / MAP	教學易讀的 genotype 文字檔與位點表	每個樣本的 ID、每個位點兩個 allele；缺失以 0 表示
PLINK BED / BIM / FAM	二進位 genotype、位點資訊、樣本資訊	三檔前綴一致，樣本與位點數正確
FASTQ	每筆通常四行：名稱、序列、分隔符號、品質字元	序列長度與品質長度一致、paired-end 配對完整
SAM / BAM / CRAM	文字 / 二進位 / 壓縮比對資料	reference、樣本 read group、排序、索引
VCF / BCF	文字 / 二進位的變異與基因型	header 定義、reference、樣本名稱及 FILTER

注意：PLINK 的 .bed 是二進位 genotype，不是描述基因體區間的文字 BED。VCF POS 為 1-based；一般區間 BED 起點為 0-based、終點不包含在區間內。CRAM 的解碼可能需要相符的 reference，交付時不能只留下單一 CRAM 檔。

想一想：拿到 VCF，是否就能把沒有列出的位點視為「沒有變異」？

解析：不行。它可能是只記錄變異的 variant-only 檔；未列出也可能是未覆蓋或未通過輸出條件。判讀前，先確認檔案的輸出規則。

三、SNP array 品質控制與分析原理

3.1 先檢查樣本，再檢查位點，必要時反覆檢查

Missingness 是缺失基因型的比例；call rate = 1 - missingness。假設一個樣本 6,000 個位點中有 2,000 個無法判定，其 call rate 約 66.7%。假設某位點 40 人中 10 人無法判定，該位點 call rate 是 75%。前者是樣本問題，後者是位點問題。

層級	指標 / 問題	原理與後續調查
Sample	call rate 偏低	可能為 DNA 品質、批次或 calling 問題；查看板位與原始訊號
Sample	heterozygosity 異常	雜合比例偏高可能與污染有關，偏低可能與近親或技術因素有關；須結合族群背景
Pair	duplicates / relatedness	比較共同基因型與等位基因共享；查樣本來源，不自動刪除其中一人
Cohort	ancestry PCA	看主要變異方向；也可能顯示批次、親緣或品質問題
Variant	missingness、MAF、HWE	分別看資料完整性、較少見 allele 的頻率及基因型分布偏離
Region	BAF / LRR、ROH	檢查連續多個探針的訊號，而非只看單點

Threshold（門檻）需由研究設計、樣本品質與分布支持。本課 --mind 0.05 與 --geno 0.05 是示範「缺失超過 5%」的篩選，不是所有研究或臨床樣本的標準。

3.2 MAF、HWE 與異常雜合度

MAF (minor allele frequency) 是較少見等位基因的比例。在無缺失的 40 名二倍體樣本中有 80 個 allele，若較少見 allele 有 8 個，MAF 為 0.1。不同族群與資料集的 MAF 可以不同；稀有變異研究不應套用常見變異分析的 MAF 排除規則。

HWE (Hardy–Weinberg equilibrium, 哈溫平衡) 在理想隨機交配等條件下, 預期基因型比例為 p^2 、 $2pq$ 、 q^2 。例如 $p=0.7$ 、 $q=0.3$, 預期比例為 0.49、0.42、0.09。偏離可由技術錯誤、族群混合、親緣、選擇或疾病相關因素造成; 不能把低 p -value 等同探針壞掉。病例對照研究常先檢查適當的對照與祖源分層; 本課先產生報表, 不自動 HWE 過濾。

Heterozygosity (雜合度) 表示可判定位點中雜合基因型的程度。PLINK .het 的 F 是相對預期雜合度的估計量, 不是直接的雜合百分比, 也不是診斷結論。離群值應先回查污染、族群與相關樣本等因素。

3.3 PCA 與親緣分析

PCA (主成分分析) 把許多 genotype 變數壓縮成少數方向。PC1 是資料變異最大的方向, PC2 與其正交。它沒有預先知道疾病或祖源標籤, 群聚不能直接稱為離散種族, 也不能證明疾病機制。

LD (連鎖不平衡) 指位點間 allele 非獨立。LD pruning 先挑選較少冗餘的位點, 避免某些高度相關區域過度主導 PCA 或親緣估計。50 5 0.2 表示以 50 個位點的視窗、每次前進 5 個位點, 依 r^2 門檻 0.2 進行修剪。

IBS 是觀察到相同 allele; IBD 是推估 allele 來自共同祖先。PLINK --genome 的 $PI_HAT = Z2 + 0.5 \times Z1$, 整合共享兩份與一份 IBD 的機率。接近 1 可提示重複樣本或同卵雙生, 但需要來源紀錄與額外 QC 確認; 族群混合也可能影響估計。[PLINK 親緣分析文件](#)

Reported-sex check 比較登錄欄位與性染色體訊號的相容性; 須考慮 X 非 PAR 區、平台、倍體、嵌合與檢體來源。PAR 是 X/Y 可對應的偽常染色體區。異常只觸發資料核對, 不自動修改紀錄, 也不推論性別認同。本次合成資料只有常染色體, 因此不執行此檢查。[PLINK QC 文件](#)

四、Array 實作與情境練習

4.1 操作練習：從 genotype 找出 QC 問題

這個練習要回答兩件事: 「哪些資料需要先檢查?」以及「你的判斷依據在哪裡?」請依序開啟資料、產生 QC 報表並找出異常, 在筆記中記錄一個暫停下游分析的理由。安裝方法見文末附錄。以下皆為 **Ubuntu / WSL 的 Bash 指令, 不是 PowerShell**。

將專案放在 Ubuntu 的 ~/KCGMH_Cource_Series。若路徑不同, 只修改第一行。cd 切換資料夾; head 顯示前幾行; --out 指定輸出前綴。

```
cd ~/KCGMH_Cource_Series/demos/lesson-01-genomics
python3 generate.py practice01
cd practice01
PLINK=plink1.9 bash ../run-array.sh
head -n 5 raw.fam
head -n 5 raw.bim
head -n 5 qc.imiss
head -n 5 qc.lmiss
```

practice01 必須是新資料夾; 產生器拒絕覆蓋既有資料。重做時使用 practice02。在既有練習目錄重跑分析腳本會取代同名結果, 故重要比較應先保留整個練習目錄。

資料共有 40 人、6,000 個常染色體 SNP, 採固定亂數種子, 包含刻意加入的缺失、重複樣本及連續純合區。這些不是疾病樣本或真實人類族群模擬; 分析結果僅供理解方法。你可以先檢查輸出, 再對照後面的結果解析。

完整腳本的核心步驟如下, 可逐行操作替代執行腳本:

```
plink1.9 --file array --make-bed --out raw
plink1.9 --bfile raw --missing --freq --hardy --het --out qc
plink1.9 --bfile raw --mind 0.05 --make-bed --out sample_qc
plink1.9 --bfile sample_qc --geno 0.05 --make-bed --out clean
plink1.9 --bfile clean --maf 0.05 --indep-pairwise 50 5 0.2 --out prune
plink1.9 --bfile clean --extract prune.prune.in --genome --out related
plink1.9 --bfile clean --extract prune.prune.in --pca 4 --out structure
plink1.9 --bfile clean --homozyg --homozyg-snp 100 --homozyg-kb 1000 --out roh
```

注意: 這份練習資料仍保留重複樣本。因此, 即使順利產生 PCA, 也不代表資料已可用於正式關聯分析。真實研究需先處理重複 / 親緣、祖源、批次與研究設計。ROH 使用未做 LD pruning 的 QC genotype, 因為它需要連續位點資訊。

先認識你會查看的輸出:

輸出檔	如何閱讀
qc.imiss	每列一個樣本；F_MISS 是該樣本缺失比例
qc.lmiss	每列一個位點；F_MISS 是該位點缺失比例
qc.het	查看樣本的觀察 / 預期純合數及 F，搭配資料背景判斷
related.genome	每列一對樣本；比較 IID1、IID2 與 PI_HAT
roh.hom	查看樣本、染色體、區段起訖位置及支持的 SNP 數

FID 是家族識別碼，IID 是個體識別碼；本資料用人工編號，不代表真實家系。你可以用 head 先閱讀欄名，再以 awk 篩出指定列。下列指令已指出幾個值得核對的樣本與位點。

用下列指令迅速找到報表證據：

```
awk 'NR==1 || $2=="S40"' qc.imiss
awk 'NR==1 || $2=="v1"' qc.lmiss
awk 'NR==1 || ($2=="S01" && $4=="S02")' related.genome
head -n 6 structure.eigenvec
head -n 6 roh.hom
wc -l raw.fam clean.fam raw.bim clean.bim
```

結果解析：請將下列內容與你的輸出比較；若不同，先確認是否使用同一份資料與相同參數，不要直接修改結果檔。

問題	預期證據與解釋
哪個樣本缺失最多？	S40，F_MISS 約 1/3；先查樣本品質
哪個位點缺失明顯？	v1；原始資料缺失超過 1/4，先查 probe/calling
篩選後留下多少？	39 個樣本、5,999 個位點
哪一對需要查重複？	S01/S02，PI_HAT 接近 1；不能單憑這項結果判定資料應刪誰
ROH 能直接當 CNV 嗎？	不行；S03 的長純合區沒有提供拷貝數證據

.eigenvec 前兩欄為 FID/IID，其後為 PC 座標；.eigenval 是各主成分的 eigenvalue（特徵值，反映變異量）。本次直接查看座標即可，不需要另外安裝繪圖套件。

4.2 情境練習：有結果，是否就能繼續分析？

以下練習不需要執行程式。請先寫下「是否能繼續分析」及「還需要哪些證據」，再閱讀解析。

1. 病例都在 A 批次、對照都在 B 批次，PCA 剛好分兩群。能說疾病造成基因體差異嗎？
2. 某樣本雜合度偏高但 call rate 正常。可以判定它通過 QC 嗎？
3. 只保留 genotype，還能完整重做原始晶片的 CNV 分析嗎？

參考解析：

1. 不能。疾病與批次完全混雜，單靠加入批次共變數也未必可辨識兩者。
2. 資訊不足。需要查污染、樣本混合、祖源與訊號分布，不能只依一個正常指標放行。
3. 通常不能完整重做。需要找回強度資料、manifest、cluster reference 與處理版本。

完成練習後，試著用一句話區分：「我已觀察到的異常」與「我懷疑但尚未證實的原因」。

五、WES/WGS：從讀段到變異

5.1 先讀 FASTQ，再談 alignment

FASTQ 品質常採 Phred 尺度： $Q = -10 \log_{10}(P_{\text{error}})$ 。Q20 對應模型中的 1% 錯誤機率，Q30 對應 0.1%；不是已實測每條 read 一定有多少錯誤。示範檔以 I 表示 Phred+33 編碼的 Q40，為理想化資料。

Alignment（比對）找出 read 可能來源位置；短讀段在重複區可能有多個候選位置。Mapping quality (MAPQ) 描述比對位置的不確定性，其定義與校準依工具而異；它與 base quality (BQ，單一鹼基品質) 不同。CIGAR 描述 read 與 reference 的對應關係，例如 150M 表示 150 個比對位置，M 本身不區分 match 與 mismatch。

實際流程還需檢查接頭、重複讀段、污染、插入片段長度、capture target 與文庫特性。不能因為流程產出 BAM，就認為 QC 完成。

Depth（深度）是位置被多少 reads 覆蓋；breadth（覆蓋廣度）是目標區達到指定深度的比例。例：平均 100x 的 WES 仍可能有某外顯子 0x。應報告「多少目標鹼基達到事先定義的可分析條件」，而不只平均值。

5.2 最小可執行示範：SAM → BAM → VCF

為了讓一般筆電短時間執行，教材提供 chrToy 2,000 bp、40 條理想讀段；SAM 已由產生器指定正確位置，**這不是實際 aligner 的輸出，也沒有測試真實比對效能**。FASTQ 用來觀察格式；本段從已比對的 SAM 起跑，不在課中重跑完整人類 WES/WGS 流程。

在第四節建立的 practice01 中執行：

```
head -n 8 reads.fastq
head -n 5 aligned.sam
bash ../run-sequence.sh
cat calls.tsv
cat review.tsv
```

拆解程式：

```
samtools faidx reference.fa
samtools view -b aligned.sam | samtools sort -o sample.bam
samtools index sample.bam
samtools flagstat sample.bam
samtools depth -aa sample.bam > depth.tsv
bcftools mpileup -Ou -f reference.fa -a FORMAT/DP,FORMAT/AD sample.bam |
  bcftools call -mv -Oz -o calls.vcf.gz
bcftools index calls.vcf.gz
bcftools query -f '%CHROM\t%POS\t%REF\t%ALT[\t%GT\t%DP\t%AD]\n' calls.vcf.gz
```

| 把前一步輸出傳給下一步；> 把輸出存檔。faidx 建立 reference 索引；sort 依座標排序；BAM index 支援依區域查詢。mpileup 整合讀段證據、估計基因型 likelihood；call 再進行變異 / 基因型推估。-Ou 是未壓縮 BCF 串流，-Oz 是壓縮 VCF。本例預期在 chrToy:1000 得到一個雜合 SNV，DP 約 40，AD 約 20,20；實際品質值可能隨版本改變。[SAMtools 文件](#)、[BCFtools 文件](#)

只看觀察到 ALT read 數並不等於 variant calling。Caller 還會使用 read/base quality、錯誤模型與先驗等資訊；真實 germline 分析可能採局部組裝等不同方法，本示範不替任何 production pipeline 背書。

5.3 VCF 判讀練習

review.vcf 是另外人工設計的 QC 案例，**不是以上 caller 的輸出**。LowDP、LowMQ 為教材自行定義的標記，不是所有 caller 的通用欄位。

欄位	說明
CHROM、POS	contig 與 1-based 位置
REF、ALT	reference allele 與替代 allele；REF 不等於健康 allele
QUAL、FILTER	位點層級品質及套用的篩選狀態；PASS 不保證正確，. 也不等於 PASS
GT	0/0 為 reference homozygous；0/1 為 heterozygous；1/1 為 ALT homozygous；./. 為缺失
AD	各 allele 的支持讀段數，順序為 REF、ALT1、ALT2...
DP	深度；可能與 AD 加總不同，依 caller 與過濾定義而定
GQ	genotype quality；描述基因型信心，與位點 QUAL 不同

```
bcftools query -f '%POS\t%FILTER[\t%GT\t%AD\t%DP\t%GQ]\n' review.vcf
```

預期：1000 的 AD=20,20、DP=40；1100 的 DP=3、GQ=8；1200 的 AD=38,2、GQ=15；1300 標記 LowMQ。

練習：哪兩筆資料的 depth 雖然高，仍需要進一步檢查？請先指出欄位證據，再解釋理由。

解析：1200 的 AD=38,2，兩種 allele 的支持數明顯不平衡，且 GQ 偏低；1300 有 LowMQ 標記，需要回到比對證據確認。兩者都說明 DP 高不等於基因型可靠。

Allele balance 可用 ALT/(REF+ALT) 作簡單示範： $20/(20+20)=0.5$ ， $2/(38+2)=0.05$ 。二倍體 germline 雜合常期待接近 0.5，但不是固定規則；抽樣、比對偏差、CNV、污染、嵌合等都可能改變它。不要直接把不平衡當成特定生物學機制。

5.4 Cohort 與 joint calling

多樣本 VCF 在 FORMAT 後面有多個樣本欄位。各自的 variant-only VCF 直接合併，不能把沒有列出的樣本位點補成 0/0；必須知道那些位置是否真的有足夠 reference 證據。GVCF 可保存非變異區段的信心資訊供特定流程 joint genotyping 使用。

Joint calling / genotyping 是跨樣本整合證據進行判定，不只是橫向拼接表格；仍需每個樣本的深度與品質控制。不能混用不相容的 caller 輸出而假設統計意義相同。

六、ROH、CNV 與整合判讀

6.1 強度的兩個方向：BAF 與 LRR

BAF (B allele frequency) 是單一樣本、單一探針的相對 allele 訊號指標，**不是族群中的 B allele 頻率**。正常二倍體常見約 0、0.5、1 三群。LRR (log R ratio) 是觀察到的總訊號相對預期訊號之 $\log_2$ 比值，經平台正規化後用來反映劑量變化。

下表是理想化示意，真實值受平台、批次、雜訊、嵌合與細胞比例等影響，不可作固定 CNV threshold：

情境	BAF 群帶示意	LRR 趨勢	需要的補充證據
正常二倍體	0、0.5、1	接近基準	強度與探針品質
缺失	常見只剩 0、1	下降	連續探針支持、邊界及其他證據
重複 / 增益	可見約 0、1/3、2/3、1	上升	正規化、區域分段與批次排查
長段純合 ROH	0、1，缺乏中間雜合帶	可仍接近基準	拷貝數與全基因體背景

```
head -n 14 intensity.csv
awk -F, 'NR==1 || $1=="deletion" || $1=="ROH"' intensity.csv
```

資料內的 LRR -0.6 / 0.3 僅用來表示下降 / 上升，不表示所有單拷貝缺失或三拷貝區段都得到相同值。CNV caller 常使用 segmentation（區域分段）：整合相鄰探針，尋找共同訊號改變；單一探針異常不夠。

ROH (run of homozygosity，連續純合區段) 是一段連續位點呈現純合。它可反映人口歷史、近親等因素，也受探針密度與錯誤影響。ROH 不等於 deletion，不可只憑一段 ROH 就診斷單親二倍體，也不應在沒有相應證據時稱為後天獲得的 LOH。

6.2 定序資料的區域證據

CNV 可利用正規化 read depth；SV 可能需異常 paired-end 距離、split reads 或組裝等證據。WES 的捕捉偏差使 read-depth CNV 分析需要適合的參考樣本與校正；本課的 samtools depth 只是觀察覆蓋，並不是完整 CNV caller。

看 toy 深度：

```
awk '$2>=995 && $2<=1005' depth.tsv
awk '{n++; if($3>=10) covered++;} END {print "fraction >=10x:", covered/n}' depth.tsv
```

分母是這個 toy contig 的 2,000 個位置，不是外顯子目標區。真實 WES 必須對正確 capture target 區域計算，避免混用分母；本例大部分位置沒有 reads 是刻意設計，不代表人類 WGS 的品質水準。

6.3 合併資料前的五項核對

1. Sample ID：臨床表格、檢體、檔案與 read group 是否一致？有沒有重複？
2. Reference build：座標與 FASTA 是否匹配？chr1 與 1 命名是否相容？
3. Allele / strand：正反股是否一致？A/T、C/G 回文 SNP 單靠 allele 字母不易判斷方向。
4. 表型與批次：缺失是否與疾病組別、晶片、定序批次相關？
5. Provenance（分析來源紀錄）：資料來源、工具版本、參數、篩選理由與排除清單能否重建？

Ascertainment bias（選取偏差）在 array 常來自預先選定的 SNP 與參考族群；換一個族群時，資訊量與表現可能不同。Imputation（基因型填補）依 LD 與參考 haplotype 推估未測位點，不是直接測量，可靠性依族群匹配、頻率及參考品質而變。

七、自我檢核與研究應用

7.1 自我檢核

請先不看解析，用自己的話回答。若能指出相關檔案、欄位或需要補充的證據，就比只記住指令更接近理解分析流程。

1. 原始強度、genotype hard call、VCF annotation 哪一個最接近直接測量？
2. WES 平均 100x，能保證每個 exon 可靠嗎？
3. PCA 分成兩群，可以直接歸因於疾病或種族嗎？
4. 有 genotype 而沒有強度，能否完整重做 array CNV QC？
5. VCF 的 PASS 且 DP=40，是否足夠接受雜合結果？

7.2 參考解析

1. 原始強度。Hard call 是演算法推估的基因型；annotation 是後續加入的基因、功能或資料庫資訊。可回看第二節的兩條資料流。
2. 不能。平均值會掩蓋低覆蓋區，需要看逐區域覆蓋與可分析比例。可回看第五節的 depth 與 breadth。
3. 不能。需核對祖源、親緣、批次與 QC，避免把資料結構直接當成生物學解釋。可回看第三節與情境練習。
4. 通常不能。需要原始或衍生強度資料，不能從離散的 hard calls 完整重建 BAF/LRR。可回看第二節與第六節。
5. 不足。還需 AD、GQ、比對、區域與樣本背景等證據。可回看第五節的 VCF 判讀案例。

7.3 套用到自己的研究

選一個你正在進行或有興趣的研究，填寫以下清單。暫時不知道的項目可標記「待確認」，作為與生物資訊人員討論時的問題。

項目	你的筆記
研究問題：希望比較或找到什麼？	
平台與版本：晶片、panel、WES 或 WGS？	
檢體設計：來源、分組、批次與重複樣本？	
樣本對照表：檢體與檔案如何對應？	
目標變異：SNV、indel、CNV、SV 或其他？	
Reference：版本與檔案來源？	
可取得的原始檔與衍生資料？	
QC 計畫：要檢查哪些樣本、位點與區域指標？	
主要輸出：需要什麼表格、圖或分析結果？	
人工確認點：哪些決定需要回查資料與共同討論？	

八、延伸練習：移除已知重複樣本後會改變什麼？

如果你已完成基本練習，可以進一步比較 raw 與 clean 的樣本 / 位點數，以及移除已知合成複本前後的 PCA。這次除了觀察結果，也請保留「移除了誰、為什麼移除、使用哪些指令」的紀錄。

下列只針對已知合成複本 F02/S02，不應移用到病人資料自行排除樣本：

```
awk '$1=="F02" && $2=="S02" {print $1, $2}' clean.fam > duplicate.remove
plink1.9 --bfile clean --remove duplicate.remove --make-bed --out unrelated_demo
plink1.9 --bfile unrelated_demo --maf 0.05 --indep-pairwise 50 5 0.2 --out prune2
plink1.9 --bfile unrelated_demo --extract prune2.prune.in --pca 4 --out structure2
wc -l clean.fam unrelated_demo.fam
head -n 6 structure2.eigenvec
```

預期 39 → 38 人。PC 的正負號可翻轉；移除樣本後頻率、軸方向與尺度也可能改變，不能將座標逐項相減就當成改善程度。真正比較需看整體結構與原始 metadata。保留 duplicate.remove、log 與理由，本例理由為「教學產生器刻意建立的 genotype 複本」。

九、名詞複習卡

名詞	一句話解釋
Genotype / allele	個體在某位點的等位基因組合 / 該位點的一種序列版本
QC	Quality control，判斷資料是否符合分析前提的品質控制
Normalization	將技術尺度調整到可比較的基準，不保證消除全部批次偏差
Call rate / missingness	可判定比例 / 缺失比例
HWE / MAF	基因型比例的理想平衡模型 / 較少見 allele 的頻率
LD / pruning	位點間的關聯 / 為特定分析減少冗餘位點
PCA / PC	將高維資料摘要為主成分 / 其中一個變異方向
Relatedness / IBD	個體間遺傳關聯 / 由共同祖先繼承相同 allele 的推估
BAF / LRR	相對 B allele 訊號 / 總訊號相對預期的對數比例
ROH / CNV	連續純合區 / 拷貝數變化，兩者不是同義詞
Alignment / caller	將 read 放到 reference / 由證據推估變異或 genotype 的工具
BQ / MAPQ / GQ	鹼基品質 / 比對品質 / 基因型品質，各自描述不同不確定性
Annotation	為變異加上基因、功能與資料庫等資訊，不等於致病性證明
Confounding	兩個因素糾纏，無法把觀察到的差異簡單歸因其中之一
Provenance	保留資料如何取得、轉換、分析與人工修改的可追溯紀錄

附錄 A：Windows 課前安裝

A1. 路線與權限

建議使用 Windows 11 與 WSL2 Ubuntu，統一執行 Linux 版 PLINK 1.9、SAMtools、BCFtools 與 Python 3。無須 R、Conda、Docker、付費晶片軟體或 GPU。玩具資料很小，但 WSL 與 Ubuntu 本身需要額外磁碟空間；課前預留數 GB 以上並確認院內政策。

WSL 的簡易安裝指令也支援 Windows 10 2004、build 19041 以上，但仍須確認作業系統支援與院內資訊安全規範。安裝需要系統管理員權限、適當虛擬化設定及網路；受管制電腦請先找資訊部門，不要繞過限制。

[Microsoft WSL 安裝說明](#)

A2. 在 PowerShell 安裝 WSL

在 Windows 搜尋 PowerShell，按右鍵「以系統管理員身分執行」：

```
wsl --install -d Ubuntu
```

依提示重新開機，開啟 Ubuntu，建立 Linux 使用者名稱與密碼。輸入密碼不顯示字元是正常現象。在 PowerShell 確認：

```
wsl --list --verbose
```

Ubuntu 的 VERSION 應為 2。若列為 1，確認硬體與政策允許後執行：

```
wsl --set-version Ubuntu 2
```

如果發行版名稱不是 Ubuntu，請使用清單上的實際名稱。已安裝者不必重複安裝；更新與問題排查以 Microsoft 官方文件為準。

A3. 在 Ubuntu 安裝本課工具

以下改在 Ubuntu 終端機執行，不要在 PowerShell 貼入 `sudo apt`：

```
sudo apt update
sudo apt install -y python3 plink1.9 samtools bcftools
python3 --version
plink1.9 --version
samtools --version
bcftools --version
```

Python 執行合成資料產生器，僅用標準函式庫，不需 `pip install`。PLINK 1.9 負責 genotype QC、PCA、親緣與 ROH；SAMtools 負責比對檔處理；BCFtools 負責 VCF 與簡化 variant calling。不要將 PLINK 2 的指令直接混入此教材。

Ubuntu 套件庫版本可能不是最新版，但需實際記錄版本。若 `plink1.9` 找不到套件，請資訊人員確認 Ubuntu 的 universe repository 是否啟用；可參考 [PLINK 官方下載頁](#)，選取與作業系統及 CPU 架構相符版本。手動安裝檔通常叫 `plink`，此時腳本使用 `PLINK=plink bash ../run-array.sh`，逐行指令也相應替換。不要下載不明來源執行檔。

A4. 將教材從 Windows 放入 Ubuntu

先在 Windows 解壓完整專案，不要只複製單一 Markdown，否則沒有示範腳本。假設資料夾位於 Windows 的 `C:\Users\你的帳號\Downloads\KCGMH_Cource_Series`，在 Ubuntu 執行以下命令；請替換「你的帳號」並確認目的資料夾尚不存在：

```
cp -r "/mnt/c/Users/你的帳號/Downloads/KCGMH_Cource_Series" ~/KCGMH_Cource_Series
cd ~/KCGMH_Cource_Series/demos/lesson-01-genomics
ls
```

應看到 `generate.py`、`run-array.sh`、`run-sequence.sh` 與 `README.md`。Windows 路徑以 `/mnt/c/` 存取 C 槽；路徑有空白時加雙引號。建議在 Ubuntu 家目錄內分析，避免混淆兩套檔案路徑。

使用 Windows 記事本或既有文字編輯器閱讀 Markdown / CSV 即可；不需另外安裝編輯器。二進位 BED/BAM 不能用記事本正常閱讀，要用相應工具。

A5. 課前完整測試與版本存檔

```
python3 generate.py preclass01
cd preclass01
PLINK=plink1.9 bash ../run-array.sh
bash ../run-sequence.sh
cat calls.tsv
wc -l clean.fam clean.bim
python3 --version > versions.txt
plink1.9 --version >> versions.txt
samtools --version >> versions.txt
bcftools --version >> versions.txt
```

確認有 39 個樣本、5,999 個 SNP，以及 chrToy:1000 雜合 SNV。保存產生器、兩個 shell 腳本、版本檔、PLINK log 與結果，不只留下截圖。

A6. 無法安裝與常見問題

現象	處理
無管理員權限或院內不允許 WSL	先洽資訊部門；也可與同學共用操作環境，或先完成第 4.2 節的情境練習
command not found	確認在 Ubuntu、安裝成功，以及名為 plink1.9 而非 plink2
No such file	先執行 pwd、ls；確認目前在產生出的練習資料夾
FileExistsError	產生器保護既有資料；改用新的 practice02 等名稱
\$'\r': command not found	腳本被轉成 Windows CRLF；以編輯器改存 UTF-8 / LF 後重跑
找不到 reference / 索引	確認 reference.fa、其 .fai 及 BAM index 都在練習目錄
PLINK 提示缺少 phenotype	本課 FAM phenotype 刻意為 -9；只做 QC，不做疾病關聯分析
沒有性染色體可做 sex check	本教材的設計限制，不是安裝錯誤

若只需 array 操作，可從官方下載 Windows 版 PLINK 1.9、解壓後在該資料夾的 PowerShell 用 `.\plink.exe --version` 確認。但本文的 Bash 腳本、awk 與管線以 WSL 為標準路線；原生 Windows 方案不等於已具備完整示範環境。

附錄 B：示範範圍與後續學習

本課刻意不安裝或執行平台原始 intensity calling 軟體，不執行人類全基因體 alignment，也不執行正式 CNV/SV caller。這些步驟的原理與輸入需求已在正文說明；實作需另備平台資料、reference、足夠計算資源與驗證過的流程。不能將玩具資料成功運行視為臨床分析驗證。

進一步閱讀：

- [PLINK 1.9](#)：指令、格式與下載。
- [PLINK 基本統計](#)：QC 欄位與限制。
- [SAMtools](#)：比對檔操作。
- [BCFtools](#)：variant calling 與 VCF 查詢。
- [Microsoft WSL](#)：Windows 安裝與權限。

軟體文件核對日期：2026-09-13。Windows 安裝步驟依官方文件整理；本專案的實際執行驗證環境與結果見 [示範說明](#)，不宣稱已在所有 Windows / Ubuntu 組合測試。