

從 SNP Array 到 WES/WGS：基因體資料分析入門

講師: 奇美醫院精準醫學核心實驗室組長邱家軍

本教材適合臨床醫師、臨床工作者及初次接觸基因體資料分析的研究人員。你不需要預先具備程式設計經驗；閱讀時可先理解資料與分析結果，再依指令完成練習。

這堂課將帶你沿著兩條路徑認識基因體分析：一條從 SNP array 的探針訊號走到基因型與區域分析，另一條從定序讀段走到比對檔與變異。重點是理解資料如何產生、分析方法依賴哪些假設，以及結果是否有足夠證據支持，而不是個別變異的致病性分類或檢測報告解讀。所有操作使用合成資料，不包含病人資訊，也不能用來驗證臨床檢測效能。

教材使用方式

你可以依序閱讀概念、操作練習及結果解析。第一次接觸指令時，不必記住所有參數；先確認每一步讀入什麼、產生什麼，以及輸出能回答哪個問題。若想跟著操作，請先完成附錄 A 的安裝；暫時無法安裝，也可以利用文中的結果表完成判讀練習。

主題	你將學會什麼
一、研究問題與平台選擇	選平台並說明需要保留的資料
二、技術與資料格式	辨認訊號、基因型、比對與變異檔
三、Array 分析與 QC	解釋 missingness、HWE、親緣與 PCA
四、Array 實作與情境練習	找出一個樣本問題與一個位點問題
五、WES/WGS 分析	串接 FASTQ、BAM、VCF 與 QC
六、整合判讀與區域分析	區分 ROH、CNV 與序列變異證據
七、自我檢核與研究應用	檢查理解程度，整理自己的分析需求

完成後，你應能選擇適合研究問題的技術、描述兩條資料流程、讀懂基本檔案與 QC 指標，並知道何時應暫停下游推論、回到原始證據。

閱讀與操作時，建議在筆記中保留三欄：「我的觀察」、「支持這項觀察的檔案或數值」、「還需要確認的資訊」。這能幫助你區分已知事實與待驗證的推論。

一、由研究問題選擇資料平台

1.1 研究案例：一份檢體能回答哪些問題？

研究團隊有一組心血管疾病病例與對照，希望回答：「常見變異是否與疾病相關？樣本是否存在重複或親緣關係？是否有罕見編碼變異？是否出現較大的拷貝數改變？」

這四個問題需要的測量方式、解析度、樣本數及統計方法不同。選擇平台前，你需要先確定想找的是哪一類變異，或想檢查哪一種資料特性。採用涵蓋範圍最大的技術，也不等於自動回答所有問題。

平台	測量方式	適合切入的問題	重要限制
SNP array (單核苷酸多型性晶片)	探針測量預設位點的等位基因訊號	常見變異、族群結構、親緣、ROH；有強度資訊時可分析部分 CNV	受探針位置、密度與設計族群影響，不能全面找新序列變異
Panel (目標基因套組)	定序選定基因或區域	聚焦特定基因集合的研究	未涵蓋區域通常無法評估，版本間目標區不同
WES (全外顯子定序)	捕捉並定序外顯子等設計目標	編碼區 SNV、小型 indel 等	捕捉效率不均，非編碼區與部分外顯子仍可能不足
WGS (全基因體定序)	不以外顯子捕捉限制定序範圍	更廣的序列變異、部分 CNV/SV 分析	重複序列與複雜區域仍困難；不同變異需要不同演算法

SNV 是單一鹼基的序列差異；SNP 通常指族群中的單核苷酸多型性，實務用語未必嚴格區分頻率。Indel 是短片段插入或缺失；CNV 是一段 DNA 的拷貝數變化；SV 是較大型的結構變異，例如倒位或易位。不要把所有變異都當成同一種 caller 可以解決。

1.2 練習：為問題選擇資料

請先不看解析，為以下需求各選一個資料來源，並寫下選擇理由：

1. 比較病例與對照的常見 SNP。
2. 尋找罕見的編碼區變異。
3. 探索非編碼區的序列變異。
4. 確認兩份資料是否可能來自同一個人。

參考解析：可分別從 array、WES、WGS、既有高品質 genotype 資料切入。這不是唯一答案；還要考慮目標區域的覆蓋、成本、樣本數與既有資料。例如，檢查重複樣本未必需要重新定序，既有且足夠的高品質 genotype 可能已能提供線索。

本節重點：面對分析結果，先問「它來自什麼訊號、經過哪些假設算出來」，再判斷它能回答什麼問題。

二、從測量訊號到檔案

2.1 SNP array：連續訊號變成離散基因型

Probe（探針）是設計用來辨識特定位置的短序列。儀器取得 fluorescence intensity（螢光強度），再經背景處理與 normalization（正規化），減少技術尺度差異。Genotype calling 依兩種等位基因訊號的群聚位置，推估 AA、AB、BB 或無法判定。

平台原始訊號（例如 IDAT 或 CEL；依廠牌 / 晶片而異）

- 背景處理、正規化、使用適當 manifest / cluster reference
- genotype calls + 品質分數 + 強度衍生資訊
- 樣本與位點 QC
 - └ genotype → PLINK → PCA、親緣、ROH 等
 - └ intensity / BAF / LRR → 區域分段與 CNV 評估

Manifest 是探針身分、位置及設計資訊；cluster reference 是用來判定基因型群聚的參考。不同平台不可任意混用。PLINK 不會直接把所有 IDAT/CEL 轉成可靠 genotype；原始訊號處理需要相容的平台流程。

Hard call 是把不確定性壓縮成 AA / AB / BB 等單一判定。沒有被保留下來的強度資訊，不能單靠 hard call 完整還原。

2.2 定序：讀段變成比對與變異

FASTQ（讀段及鹼基品質）

- read QC → alignment（對到參考基因體）
- BAM / CRAM（比對位置及證據）
- variant calling（估計基因型與變異）
- VCF / BCF → filtering、annotation、cohort analysis

Reference genome（參考基因體）是共同座標與序列基準，不代表每個人的正常或健康基因體。GRCh37 與 GRCh38 座標不能直接混用；即使版本名稱相同，也需確認 contig、decoy、FASTA 內容及索引一致。

2.3 常見檔案速查

檔案	存什麼	第一眼要檢查什麼
IDAT / CEL	平台相關的原始晶片訊號	晶片型號、樣本對照表與處理版本
PED / MAP	教學易讀的 genotype 文字檔與位點表	每個樣本的 ID、每個位點兩個 allele；缺失以 0 表示
PLINK BED / BIM / FAM	二進位 genotype、位點資訊、樣本資訊	三檔前綴一致，樣本與位點數正確
FASTQ	每筆通常四行：名稱、序列、分隔符號、品質字元	序列長度與品質長度一致、paired-end 配對完整
SAM / BAM / CRAM	文字 / 二進位 / 壓縮比對資料	reference、樣本 read group、排序、索引
VCF / BCF	文字 / 二進位的變異與基因型	header 定義、reference、樣本名稱及 FILTER

注意：PLINK 的 .bed 是二進位 genotype，不是描述基因體區間的文字 BED。VCF POS 為 1-based；一般區間 BED 起點為 0-based、終點不包含在區間內。CRAM 的解碼可能需要相符的 reference，交付時不能只留下單一 CRAM 檔。

想一想：拿到 VCF，是否就能把沒有列出的位點視為「沒有變異」？

解析：不行。它可能是只記錄變異的 variant-only 檔；未列出也可能是未覆蓋或未通過輸出條件。判讀前，先確認檔案的輸出規則。

三、SNP array 品質控制與分析原理

3.1 先檢查樣本，再檢查位點，必要時反覆檢查

Missingness 是缺失基因型的比例；call rate = 1 - missingness。假設一個樣本 6,000 個位點中有 2,000 個無法判定，其 call rate 約 66.7%。假設某位點 40 人中 10 人無法判定，該位點 call rate 是 75%。前者是樣本問題，後者是位點問題。

層級	指標 / 問題	原理與後續調查
Sample	call rate 偏低	可能為 DNA 品質、批次或 calling 問題；查看板位與原始訊號
Sample	heterozygosity 異常	雜合比例偏高可能與污染有關，偏低可能與近親或技術因素有關；須結合族群背景
Pair	duplicates / relatedness	比較共同基因型與等位基因共享；查樣本來源，不自動刪除其中一人
Cohort	ancestry PCA	看主要變異方向；也可能顯示批次、親緣或品質問題
Variant	missingness、MAF、HWE	分別看資料完整性、較少見 allele 的頻率及基因型分布偏離
Region	BAF / LRR、ROH	檢查連續多個探針的訊號，而非只看單點

Threshold（門檻）需由研究設計、樣本品質與分布支持。本課 --mind 0.05 與 --geno 0.05 是示範「缺失超過 5%」的篩選，不是所有研究或臨床樣本的標準。

3.2 MAF、HWE 與異常雜合度

MAF (minor allele frequency) 是較少見等位基因的比例。在無缺失的 40 名二倍體樣本中有 80 個 allele，若較少見 allele 有 8 個，MAF 為 0.1。不同族群與資料集的 MAF 可以不同；稀有變異研究不應套用常見變異分析的 MAF 排除規則。

HWE (Hardy–Weinberg equilibrium, 哈溫平衡) 在理想隨機交配等條件下, 預期基因型比例為 p^2 、 $2pq$ 、 q^2 。例如 $p=0.7$ 、 $q=0.3$, 預期比例為 0.49、0.42、0.09。偏離可由技術錯誤、族群混合、親緣、選擇或疾病相關因素造成; 不能把低 p -value 等同探針壞掉。病例對照研究常先檢查適當的對照與祖源分層; 本課先產生報表, 不自動 HWE 過濾。

Heterozygosity (雜合度) 表示可判定位點中雜合基因型的程度。PLINK .het 的 F 是相對預期雜合度的估計量, 不是直接的雜合百分比, 也不是診斷結論。離群值應先回查污染、族群與相關樣本等因素。

3.3 PCA 與親緣分析

PCA (主成分分析) 把許多 genotype 變數壓縮成少數方向。PC1 是資料變異最大的方向, PC2 與其正交。它沒有預先知道疾病或祖源標籤, 群聚不能直接稱為離散種族, 也不能證明疾病機制。

LD (連鎖不平衡) 指位點間 allele 非獨立。LD pruning 先挑選較少冗餘的位點, 避免某些高度相關區域過度主導 PCA 或親緣估計。50 5 0.2 表示以 50 個位點的視窗、每次前進 5 個位點, 依 r^2 門檻 0.2 進行修剪。

IBS 是觀察到相同 allele; IBD 是推估 allele 來自共同祖先。PLINK --genome 的 $PI_HAT = Z2 + 0.5 \times Z1$, 整合共享兩份與一份 IBD 的機率。接近 1 可提示重複樣本或同卵雙生, 但需要來源紀錄與額外 QC 確認; 族群混合也可能影響估計。[PLINK 親緣分析文件](#)

Reported-sex check 比較登錄欄位與性染色體訊號的相容性; 須考慮 X 非 PAR 區、平台、倍體、嵌合與檢體來源。PAR 是 X/Y 可對應的偽常染色體區。異常只觸發資料核對, 不自動修改紀錄, 也不推論性別認同。本次合成資料只有常染色體, 因此不執行此檢查。[PLINK QC 文件](#)

四、Array 實作與情境練習

4.1 操作練習：從 genotype 找出 QC 問題

這個練習要回答兩件事: 「哪些資料需要先檢查?」以及「你的判斷依據在哪裡?」請依序開啟資料、產生 QC 報表並找出異常, 在筆記中記錄一個暫停下游分析的理由。安裝方法見文末附錄。以下在 Windows 的 WSL Ubuntu、macOS Terminal 或 Linux Terminal 操作, .sh 用 Bash 執行, 不是在 PowerShell 輸入。先依附錄 A 安裝並檢查工具。

將完整專案放在目前使用者的 ~/ClinicalBioinfoCourse。若路徑不同, 只修改第一行。cd 切換資料夾; head 顯示前幾行; --out 指定輸出前綴。

```
cd ~/ClinicalBioinfoCourse/demos/lesson-01-genomics
python3 generate.py practice-local01
cd practice-local01
PLINK=plink1.9 bash ../run-array.sh
head -n 5 raw.fam
head -n 5 raw.bim
head -n 5 qc.imiss
head -n 5 qc.lmiss
```

practice-local01 必須是新資料夾; 產生器拒絕覆蓋既有資料。重做時使用 practice-local02。在既有練習目錄重跑分析腳本會取代同名結果, 故重要比較應先保留整個練習目錄。

資料共有 40 人、6,000 個常染色體 SNP, 採固定亂數種子, 包含刻意加入的缺失、重複樣本及連續純合區。這些不是疾病樣本或真實人類族群模擬; 分析結果僅供理解方法。你可以先檢查輸出, 再對照後面的結果解析。

完整腳本的核心步驟如下, 可逐行操作替代執行腳本:

```
plink1.9 --file array --make-bed --out raw
plink1.9 --bfile raw --missing --freq --hardy --het --out qc
plink1.9 --bfile raw --mind 0.05 --make-bed --out sample_qc
plink1.9 --bfile sample_qc --geno 0.05 --make-bed --out clean
plink1.9 --bfile clean --maf 0.05 --indep-pairwise 50 5 0.2 --out prune
plink1.9 --bfile clean --extract prune.prune.in --genome --out related
plink1.9 --bfile clean --extract prune.prune.in --pca 4 --out structure
plink1.9 --bfile clean --homozyg --homozyg-snp 100 --homozyg-kb 1000 --out roh
```

注意: 這份練習資料仍保留重複樣本。因此, 即使順利產生 PCA, 也不代表資料已可用於正式關聯分析。真實研究需先處理重複 / 親緣、祖源、批次與研究設計。ROH 使用未做 LD pruning 的 QC genotype, 因為它需要連續位點資訊。

先認識你會查看的輸出：

輸出檔	如何閱讀
qc.imiss	每列一個樣本；F_MISS 是該樣本缺失比例
qc.lmiss	每列一個位點；F_MISS 是該位點缺失比例
qc.het	查看樣本的觀察 / 預期純合數及 F，搭配資料背景判斷
related.genome	每列一對樣本；比較 IID1、IID2 與 PI_HAT
roh.hom	查看樣本、染色體、區段起訖位置及支持的 SNP 數

FID 是家族識別碼，IID 是個體識別碼；本資料用人工編號，不代表真實家系。你可以用 head 先閱讀欄名，再以 awk 篩出指定列。下列指令已指出幾個值得核對的樣本與位點。

用下列指令迅速找到報表證據：

```
awk 'NR==1 || $2=="S40"' qc.imiss
awk 'NR==1 || $2=="v1"' qc.lmiss
awk 'NR==1 || ($2=="S01" && $4=="S02")' related.genome
head -n 6 structure.eigenvec
head -n 6 roh.hom
wc -l raw.fam clean.fam raw.bim clean.bim
```

結果解析：請將下列內容與你的輸出比較；若不同，先確認是否使用同一份資料與相同參數，不要直接修改結果檔。

問題	預期證據與解釋
哪個樣本缺失最多？	S40，F_MISS 約 1/3；先查樣本品質
哪個位點缺失明顯？	v1；原始資料缺失超過 1/4，先查 probe/calling
篩選後留下多少？	39 個樣本、5,999 個位點
哪一對需要查重複？	S01/S02，PI_HAT 接近 1；不能單憑這項結果判定資料應刪誰
ROH 能直接當 CNV 嗎？	不行；S03 的長純合區沒有提供拷貝數證據

.eigenvec 前兩欄為 FID/IID，其後為 PC 座標；.eigenval 是各主成分的 eigenvalue（特徵值，反映變異量）。本次直接查看座標即可，不需要另外安裝繪圖套件。

4.2 情境練習：有結果，是否就能繼續分析？

以下練習不需要執行程式。請先寫下「是否能繼續分析」及「還需要哪些證據」，再閱讀解析。

1. 病例都在 A 批次、對照都在 B 批次，PCA 剛好分兩群。能說疾病造成基因體差異嗎？
2. 某樣本雜合度偏高但 call rate 正常。可以判定它通過 QC 嗎？
3. 只保留 genotype，還能完整重做原始晶片的 CNV 分析嗎？

參考解析：

1. 不能。疾病與批次完全混雜，單靠加入批次共變數也未必可辨識兩者。
2. 資訊不足。需要查污染、樣本混合、祖源與訊號分布，不能只依一個正常指標放行。
3. 通常不能完整重做。需要找回強度資料、manifest、cluster reference 與處理版本。

完成練習後，試著用一句話區分：「我已觀察到的異常」與「我懷疑但尚未證實的原因」。

五、WES/WGS：從讀段到變異

5.1 先讀 FASTQ，再談 alignment

FASTQ 品質常採 Phred 尺度： $Q = -10 \log_{10}(P_{\text{error}})$ 。Q20 對應模型中的 1% 錯誤機率，Q30 對應 0.1%；不是已實測每條 read 一定有多少錯誤。示範檔以 I 表示 Phred+33 編碼的 Q40，為理想化資料。

Alignment (比對) 找出 read 可能來源位置；短讀段在重複區可能有多個候選位置。Mapping quality (MAPQ) 描述比對位置的不確定性，其定義與校準依工具而異；它與 base quality (BQ, 單一鹼基品質) 不同。CIGAR 描述 read 與 reference 的對應關係，例如 150M 表示 150 個比對位置，M 本身不區分 match 與 mismatch。實際流程還需檢查接頭、重複讀段、污染、插入片段長度、capture target 與文庫特性。不能因為流程產出 BAM，就認為 QC 完成。

Depth (深度) 是位置被多少 reads 覆蓋；breadth (覆蓋廣度) 是目標區達到指定深度的比例。例：平均 100× 的 WES 仍可能有某外顯子 0×。應報告「多少目標鹼基達到事先定義的可分析條件」，而不只平均值。

5.2 最小可執行示範：SAM → BAM → VCF

為了讓一般筆電短時間執行，教材提供 chrToy 2,000 bp、40 條理想讀段；SAM 已由產生器指定正確位置，這**不是實際 aligner 的輸出**，也沒有測試真實比對效能。FASTQ 用來觀察格式；本段從已比對的 SAM 起跑，不在課中重跑完整人類 WES/WGS 流程。

在第四節建立的 practice-local01 中執行：

```
head -n 8 reads.fastq
head -n 5 aligned.sam
bash ./run-sequence.sh
cat calls.tsv
cat review.tsv
```

拆解程式：

```
samtools faidx reference.fa
samtools view -b aligned.sam | samtools sort -o sample.bam
samtools index sample.bam
samtools flagstat sample.bam
samtools depth -aa sample.bam > depth.tsv
bcftools mpileup -Ou -f reference.fa -a FORMAT/DP,FORMAT/AD sample.bam |
  bcftools call -mv -Oz -o calls.vcf.gz
bcftools index calls.vcf.gz
bcftools query -f '%CHROM\t%POS\t%REF\t%ALT[\t%GT\t%DP\t%AD]\n' calls.vcf.gz
```

| 把前一步輸出傳給下一步；> 把輸出存檔。faidx 建立 reference 索引；sort 依座標排序；BAM index 支援依區域查詢。mpileup 整合讀段證據、估計基因型 likelihood；call 再進行變異 / 基因型推估。-Ou 是未壓縮 BCF 串流，-Oz 是壓縮 VCF。本例預期在 chrToy:1000 得到一個雜合 SNV，DP 約 40，AD 約 20,20；實際品質值可能隨版本改變。[SAMtools 文件](#)、[BCFtools 文件](#)

只看觀察到 ALT read 數並不等於 variant calling。Caller 還會使用 read/base quality、錯誤模型與先驗等資訊；真實 germline 分析可能採局部組裝等不同方法，本示範不替任何 production pipeline 背書。

5.3 VCF 判讀練習

review.vcf 是另外人工設計的 QC 案例，**不是以上 caller 的輸出**。LowDP、LowMQ 為教材自行定義的標記，不是所有 caller 的通用欄位。

欄位	說明
CHROM、POS	contig 與 1-based 位置
REF、ALT	reference allele 與替代 allele；REF 不等於健康 allele
QUAL、FILTER	位點層級品質及套用的篩選狀態；PASS 不保證正確，. 也不等於 PASS
GT	0/0 為 reference homozygous；0/1 為 heterozygous；1/1 為 ALT homozygous；./. 為缺失
AD	各 allele 的支持讀段數，順序為 REF、ALT1、ALT2...
DP	深度；可能與 AD 加總不同，依 caller 與過濾定義而定
GQ	genotype quality；描述基因型信心，與位點 QUAL 不同

```
bcftools query -f '%POS\t%FILTER[\t%GT\t%AD\t%DP\t%GQ]\n' review.vcf
```

預期：1000 的 AD=20,20、DP=40；1100 的 DP=3、GQ=8；1200 的 AD=38,2、GQ=15；1300 標記 LowMQ。

練習：哪兩筆資料的 depth 雖然高，仍需要進一步檢查？請先指出欄位證據，再解釋理由。

解析：1200 的 AD=38,2，兩種 allele 的支持數明顯不平衡，且 GQ 偏低；1300 有 LowMQ 標記，需要回到比對證據確認。兩者都說明 DP 高不等於基因型可靠。

Allele balance 可用 ALT/(REF+ALT) 作簡單示範：20/(20+20)=0.5，2/(38+2)=0.05。二倍體 germline 雜合常期待接近 0.5，但不是固定規則；抽樣、比對偏差、CNV、污染、嵌合等都可能改變它。不要直接把不平衡當成特定生物學機制。

5.4 Cohort 與 joint calling

多樣本 VCF 在 FORMAT 後面有多個樣本欄位。各自的 variant-only VCF 直接合併，不能把沒有列出的樣本位點補成 0/0；必須知道那些位置是否真的有足夠 reference 證據。GVCF 可保存非變異區段的信心資訊供特定流程 joint genotyping 使用。

Joint calling / genotyping 是跨樣本整合證據進行判定，不只是橫向拼接表格；仍需每個樣本的深度與品質控制。不能混用不相容的 caller 輸出而假設統計意義相同。

六、ROH、CNV 與整合判讀

6.1 強度的兩個方向：BAF 與 LRR

BAF (B allele frequency) 是單一樣本、單一探針的相對 allele 訊號指標，**不是族群中的 B allele 頻率**。正常二倍體常見約 0、0.5、1 三群。LRR (log R ratio) 是觀察到的總訊號相對預期訊號之 log2 比值，經平台正規化後用來反映劑量變化。

下表是理想化示意，真實值受平台、批次、雜訊、嵌合與細胞比例等影響，不可作固定 CNV threshold：

情境	BAF 群帶示意	LRR 趨勢	需要的補充證據
正常二倍體	0、0.5、1	接近基準	強度與探針品質
缺失	常見只剩 0、1	下降	連續探針支持、邊界及其他證據
重複 / 增益	可見約 0、1/3、2/3、1	上升	正規化、區域分段與批次排查
長段純合 ROH	0、1，缺乏中間雜合帶	可仍接近基準	拷貝數與全基因體背景

```
head -n 14 intensity.csv
awk -F, 'NR==1 || $1=="deletion" || $1=="ROH"' intensity.csv
```

資料內的 LRR -0.6 / 0.3 僅用來表示下降 / 上升，不表示所有單拷貝缺失或三拷貝區段都得到相同值。CNV caller 常使用 segmentation (區域分段)：整合相鄰探針，尋找共同訊號改變；單一探針異常不夠。

ROH (run of homozygosity, 連續純合區段) 是一段連續位點呈現純合。它可反映人口歷史、近親等因素，也受探針密度與錯誤影響。ROH 不等於 deletion，不可只憑一段 ROH 就診斷單親二倍體，也不應在沒有相應證據時稱為後天獲得的 LOH。

6.2 定序資料的區域證據

CNV 可利用正規化 read depth；SV 可能需異常 paired-end 距離、split reads 或組裝等證據。WES 的捕捉偏差使 read-depth CNV 分析需要適合的參考樣本與校正；本課的 samtools depth 只是觀察覆蓋，並不是完整 CNV caller。

看 toy 深度：

```
awk '$2>=995 && $2<=1005' depth.tsv  
awk '{n++; if($3>=10) covered++;} END {print "fraction >=10x:", covered/n}' depth.tsv
```

分母是這個 toy contig 的 2,000 個位置，不是外顯子目標區。真實 WES 必須對正確 capture target 區域計算，避免混用分母；本例大部分位置沒有 reads 是刻意設計，不代表人類 WGS 的品質水準。

6.3 合併資料前的五項核對

1. Sample ID：臨床表格、檢體、檔案與 read group 是否一致？有沒有重複？
2. Reference build：座標與 FASTA 是否匹配？chr1 與 1 命名是否相容？
3. Allele / strand：正反股是否一致？A/T、C/G 回文 SNP 單靠 allele 字母不易判斷方向。
4. 表型與批次：缺失是否與疾病組別、晶片、定序批次相關？
5. Provenance（分析來源紀錄）：資料來源、工具版本、參數、篩選理由與排除清單能否重建？

Ascertainment bias（選取偏差）在 array 常來自預先選定的 SNP 與參考族群；換一個族群時，資訊量與表現可能不同。Imputation（基因型填補）依 LD 與參考 haplotype 推估未測位點，不是直接測量，可靠性依族群匹配、頻率及參考品質而變。

七、自我檢核與研究應用

7.1 自我檢核

請先不看解析，用自己的話回答。若能指出相關檔案、欄位或需要補充的證據，就比只記住指令更接近理解分析流程。

1. 原始強度、genotype hard call、VCF annotation 哪一個最接近直接測量？
2. WES 平均 100x，能保證每個 exon 可靠嗎？
3. PCA 分成兩群，可以直接歸因於疾病或種族嗎？
4. 有 genotype 而沒有強度，能否完整重做 array CNV QC？
5. VCF 的 PASS 且 DP=40，是否足夠接受雜合結果？

7.2 參考解析

1. 原始強度。Hard call 是演算法推估的基因型；annotation 是後續加入的基因、功能或資料庫資訊。可回看第二節的兩條資料流。
2. 不能。平均值會掩蓋低覆蓋區，需要看逐區域覆蓋與可分析比例。可回看第五節的 depth 與 breadth。
3. 不能。需核對祖源、親緣、批次與 QC，避免把資料結構直接當成生物學解釋。可回看第三節與情境練習。
4. 通常不能。需要原始或衍生強度資料，不能從離散的 hard calls 完整重建 BAF/LRR。可回看第二節與第六節。
5. 不足。還需 AD、GQ、比對、區域與樣本背景等證據。可回看第五節的 VCF 判讀案例。

7.3 套用到自己的研究

選一個你正在進行或有興趣的研究，填寫以下清單。暫時不知道的項目可標記「待確認」，作為與生物資訊人員討論時的問題。

項目	你的筆記
研究問題：希望比較或找到什麼？	
平台與版本：晶片、panel、WES 或 WGS？	
檢體設計：來源、分組、批次與重複樣本？	
樣本對照表：檢體與檔案如何對應？	
目標變異：SNV、indel、CNV、SV 或其他？	
Reference：版本與檔案來源？	
可取得的原始檔與衍生資料？	
QC 計畫：要檢查哪些樣本、位點與區域指標？	
主要輸出：需要什麼表格、圖或分析結果？	
人工確認點：哪些決定需要回查資料與共同討論？	

八、延伸練習：移除已知重複樣本後會改變什麼？

如果你已完成基本練習，可以進一步比較 raw 與 clean 的樣本 / 位點數，以及移除已知合成複本前後的 PCA。這次除了觀察結果，也請保留「移除了誰、為什麼移除、使用哪些指令」的紀錄。

下列只針對已知合成複本 F02/S02，不應移用到病人資料自行排除樣本：

```
awk '$1=="F02" && $2=="S02" {print $1, $2}' clean.fam > duplicate.remove
plink1.9 --bfile clean --remove duplicate.remove --make-bed --out unrelated_demo
plink1.9 --bfile unrelated_demo --maf 0.05 --indep-pairwise 50 5 0.2 --out prune2
plink1.9 --bfile unrelated_demo --extract prune2.prune.in --pca 4 --out structure2
wc -l clean.fam unrelated_demo.fam
head -n 6 structure2.eigenvec
```

預期 39 → 38 人。PC 的正負號可翻轉；移除樣本後頻率、軸方向與尺度也可能改變，不能將座標逐項相減就當成改善程度。真正比較需看整體結構與原始 metadata。保留 duplicate.remove、log 與理由，本例理由為「教學產生器刻意建立的 genotype 複本」。

九、名詞複習卡

名詞	一句話解釋
Genotype / allele	個體在某位點的等位基因組合 / 該位點的一種序列版本
QC	Quality control, 判斷資料是否符合分析前提的品質控制
Normalization	將技術尺度調整到可比較的基準, 不保證消除全部批次偏差
Call rate / missingness	可判定比例 / 缺失比例
HWE / MAF	基因型比例的理想平衡模型 / 較少見 allele 的頻率
LD / pruning	位點間的關聯 / 為特定分析減少冗餘位點
PCA / PC	將高維資料摘要為主成分 / 其中一個變異方向
Relatedness / IBD	個體間遺傳關聯 / 由共同祖先繼承相同 allele 的推估
BAF / LRR	相對 B allele 訊號 / 總訊號相對預期的對數比例
ROH / CNV	連續純合區 / 拷貝數變化, 兩者不是同義詞
Alignment / caller	將 read 放到 reference / 由證據推估變異或 genotype 的工具
BQ / MAPQ / GQ	鹼基品質 / 比對品質 / 基因型品質, 各自描述不同不確定性
Annotation	為變異加上基因、功能與資料庫等資訊, 不等於致病性證明
Confounding	兩個因素糾纏, 無法把觀察到的差異簡單歸因其中之一
Provenance	保留資料如何取得、轉換、分析與人工修改的可追溯紀錄

附錄 A：依作業系統安裝，到第一次成功執行

A1. 選擇操作路線與必要工具

依序完成「選作業系統 → 安裝工具 → 下載完整專案 → 產生自己的練習資料 → 執行腳本 → 核對結果」。只閱讀自己系統的安裝分支，再接共同步驟。所有資料均為合成教學資料，不要把病人資料放進這個公開專案。

電腦	安裝路線	之後在哪裡輸入指令
Windows 11、Intel / AMD 64-bit	A2：WSL2 + Ubuntu 24.04	Ubuntu；只有安裝 WSL 使用 PowerShell
macOS、Apple Silicon 或 Intel	A3：Homebrew + 官方 PLINK 1.9	Terminal（終端機）
Linux、Ubuntu 24.04 / 相容 Debian 系統	A4：系統套件管理員	Linux Terminal
Windows ARM / Linux ARM64、其他 Linux	先看 A4 相容性限制	不可直接假設 x86_64 執行檔可用

Windows 可由「設定 → 系統 → 關於 → 系統類型」確認處理器；Mac 可由「蘋果選單 → 關於這台 Mac」確認晶片。Linux / WSL 的 `uname -m` 若顯示 `x86_64`，是 Intel / AMD 64-bit；`arm64` 是 ARM64。Mac 原生 Apple Silicon 終端機通常顯示 `arm64`。

工具	本次用途	哪堂需要
Git	下載完整教材，記錄教材版本	兩堂
Python 3.8 以上	產生合成資料、自動核對；只用標準函式庫	兩堂
Bash	依序執行 .sh 腳本、連接工具	兩堂
SAMtools	SAM/BAM 轉換、排序、索引與讀段統計	兩堂
BCFtools	VCF 處理；第一堂另做小型 variant calling	兩堂
PLINK 1.9	Genotype QC、PCA、親緣與 ROH	第一堂
IGV Desktop	圖形化查看 reference、BAM、VCF、SEG	第二堂的視覺核對

不需 R、Docker、Conda、GPU、付費軟體或額外 Python 套件。FastQC、aligner、Mutect2 在概念部分介紹，但本次腳本沒有呼叫它們，不必額外安裝。第二堂不使用第一堂的輸出，可以單獨操作。

請為 WSL / 開發工具預留數 GB 磁碟空間並確認能連線至官方下載站與 GitHub；合成資料本身很小。安裝可能需要管理員權限，分析則不需要 sudo。院內電腦請先取得核准；不能安裝時請資訊人員提供合規環境，勿停用防護或繞過權限。

A2. Windows : WSL2 + Ubuntu

步驟 1：安裝 Linux 環境。 WSL (Windows Subsystem for Linux) 讓 Windows 使用 Linux 工具。本路線選 Windows 11 與 Ubuntu 24.04 LTS。Microsoft 簡易指令也支援 Windows 10 2004、build 19041 以上；作業系統維護狀態與院內政策另行確認。[Microsoft 安裝說明](#)

在開始選單搜尋 PowerShell，按右鍵「以系統管理員身分執行」，先查已安裝及可下載的發行版：

```
wsl --list --verbose
wsl --list --online
```

尚未安裝者，確認線上清單有 Ubuntu-24.04 後執行：

```
wsl --install -d Ubuntu-24.04
```

依提示重新開機，從開始選單開啟 Ubuntu 24.04，建立 Linux 帳號與密碼；它們可以不同於 Windows 帳號。輸入密碼不顯示字元是正常現象。已有可用 Ubuntu 不必重裝，尤其不要使用 wsl --unregister，這會刪除該環境與資料。

步驟 2：確認 WSL2。 在 PowerShell 再執行 wsl --list --verbose，Ubuntu 的 VERSION 應為 2。若為 1，請先確認硬體虛擬化與政策允許，再執行：

```
wsl --set-version Ubuntu-24.04 2
```

發行版名稱必須與清單一致；若清單顯示 Ubuntu，就改用 Ubuntu。

步驟 3：改在 Ubuntu 視窗安裝工具。 PowerShell 常見提示為 PS C:\...>；Ubuntu 通常為 使用者@電腦:~\$。下面指令不是貼在 PowerShell、CMD、Git Bash 或 Python 的 >>>。

```
uname -m
sudo apt update
sudo apt install -y git python3 samtools bcftools
```

apt update 更新套件清單，apt install 安裝工具；sudo 要求剛設定的 Linux 密碼。第一堂另外安裝：

```
sudo apt install -y plink1.9
plink1.9 --version
```

PLINK 指令以 Ubuntu 24.04 的 x86_64 為主要路線；ARM 電腦或找不到套件請看 A4。不要改裝 PLINK 2 當成同一工具。完成後跳到 A5，不需再裝 Windows 版 Python / SAMtools。

A3. macOS : Homebrew + PLINK 1.9

步驟 1：打開 Terminal。 按 Command+空白鍵，搜尋 Terminal，再查看系統：

```
sw_vers
uname -m
```

先核對 [Homebrew 支援範圍](#)。舊 macOS / Intel Mac 的支援程度不同，安裝若提示不支援，應請資訊人員安排相容工具或核准的 Linux 環境，勿強行覆寫系統。

步驟 2：安裝 Homebrew。 它是管理命令列軟體的工具。先執行 `brew --version`；已有版本就跳過重裝。否則前往 [Homebrew 官網](#)，確認來源與權限後，在 Terminal 執行官方安裝指令：

```
/bin/bash -c "$(curl -fsSL https://raw.githubusercontent.com/Homebrew/install/HEAD/install.sh)"
```

這行會下載並執行安裝程式，請閱讀提示再同意。若要求 Command Line Tools，依提示完成，或執行 `xcode-select --install` 並於系統視窗安裝；不用下載完整 Xcode。

安裝結束，照畫面 **Next steps** 設定 `shellenv`，讓終端機找到 `brew`。若目前視窗仍找不到，Apple Silicon 的標準安裝位置可執行：

```
eval "$(/opt/homebrew/bin/brew shellenv)"
```

Intel Mac 的標準位置則用：

```
eval "$(/usr/local/bin/brew shellenv)"
```

只選符合安裝位置的一段。`eval` 在此載入 Homebrew 的環境設定；這一行僅影響目前視窗，仍應依 Next steps 完成啟動設定。再用 `brew --version` 確認。

步驟 3：安裝兩堂共用工具。

```
brew install git python samtools bcftools
```

`python` 是套件名稱，執行時仍叫 `python3`。不要在 `brew install` 前加 `sudo`。套件名稱見 [SAMtools formula](#) 與 [BCFtools formula](#)。

步驟 4：第一堂另裝 PLINK。 第二堂可以跳過。於 [PLINK 1.9 官方頁](#)選 macOS 64-bit stable，不要選 PLINK 2。以下固定使用 2026-09-27 版本；本次實際檢查它是包含 x86_64 與 arm64 的 Universal binary，Intel 與 Apple Silicon 可用同一檔案。

```
mkdir -p "$HOME/bioinfo-tools/plink19-20260927"
cd "$HOME/bioinfo-tools/plink19-20260927"
curl -fL \
  https://s3.amazonaws.com/plink1-assets/plink_mac_20260927.zip \
  -o plink.zip
unzip -n plink.zip
file plink
./plink --version
```

`mkdir -p` 建立工具目錄；`curl -fL` 下載並在 HTTP 錯誤時失敗；`unzip -n` 解壓但不覆蓋既有檔案；`file` 顯示程式架構。每一步無錯誤才繼續。版本應顯示 PLINK v1.9.0。本例不用一律加裝 Rosetta；如果另用 Intel-only 舊版，才需核對 [Apple Rosetta 說明](#)。

為了與 Ubuntu 一樣使用 `plink1.9` 命令，把已確認來源的程式放到個人工具目錄。若目的地已有其他版本，先備份或改名，不要直接取代。

```
mkdir -p "$HOME/.local/bin"
install -m 755 ./plink "$HOME/.local/bin/plink1.9"
export PATH="$HOME/.local/bin:$PATH"
plink1.9 --version
```

`install -m 755` 複製並賦予執行權限；PATH 是終端機搜尋程式的目錄清單。`export` 只在目前視窗與子程式有效，**每次新開 Terminal 執行第一堂前，再執行 `export PATH="$HOME/.local/bin:$PATH"`**。熟悉 shell 者可自行寫入個人啟動檔。不要只設定 alias，因為子腳本未必能使用。

若 macOS 阻擋下載程式，確認官方來源後依「隱私權與安全性」提示或洽資訊人員處理，不要全域停用 Gatekeeper。完成後前往 A5。

A4. Linux：套件安裝與相容性

Linux 不需安裝 WSL 或 Homebrew。打開 Terminal，確認發行版與 CPU：

```
cat /etc/os-release
uname -m
```

以下以 **Ubuntu 24.04 LTS**、**x86_64** 為基準。Debian 可使用相同套件管理命令，但套件版本與架構須另確認。Fedora、Rocky、Arch 不是 apt 系統，請由資訊人員用該系統的套件管理方式提供 A1 工具，再從 A5 檢查，不要直接照貼 apt。

```
sudo apt update
sudo apt install -y git python3 samtools bcftools
```

第一堂另外執行：

```
sudo apt install -y plink1.9
plink1.9 --version
```

若 Unable to locate package plink1.9，先查拼字、apt update 是否成功及發行版。Ubuntu 的套件位於 **universe**；只有院內允許新增來源時才執行：

```
sudo apt install -y software-properties-common
sudo add-apt-repository universe
sudo apt update
sudo apt install -y plink1.9
```

這段新增來源只適用 Ubuntu，不適用 Debian。伺服器沒有 sudo 者，請管理員安裝或啟用既有環境，不要修改系統權限。

ARM64 限制： [Ubuntu 24.04 的 plink1.9 套件頁](#)目前沒有 ARM64 套件。Windows ARM 的 WSL、ARM Linux 不應下載 x86_64 程式硬跑。若 Python、SAMtools、BCFtools 可用，仍可完成第一堂定序部分及第二堂命令列練習；array 部分請資訊人員提供經確認的 PLINK 1.9 ARM 編譯版，或改用核准的 x86_64 Ubuntu 電腦 / 伺服器。本教材不宣稱已驗證 ARM Linux 的 array 流程。使用遠端主機時，安裝與腳本都在遠端執行，供 IGV 使用的結果需另下載到桌面電腦。

A5. 共同步驟：確認工具與下載專案

Windows 在 Ubuntu，macOS / Linux 在 Terminal 執行。後文 .sh 都用 bash 呼叫，因此 Mac 預設是 zsh 也能操作。

```
git --version
python3 --version
bash --version
samtools --version
bcftools --version
```

每行應印出版本，不是 command not found；SAMtools / BCFtools 顯示多行編譯資訊正常。Python 至少 3.8，因第二堂使用 math.comb。第一堂加跑 `plink1.9 --version`，確認是 PLINK 1.9 / 1.90 系列，不是 2.x 或 PuTTY 的同名連線工具。

第一次下載： 假設家目錄尚無 ClinicalBioinfoCourse 資料夾：

```
cd ~
git clone https://github.com/godkin1211/ClinicalBioinfoCourse.git
cd ClinicalBioinfoCourse
pwd
ls
git rev-parse --short HEAD
```

公開專案不需 GitHub 帳號或 token。cd ~ 回到目前使用者的家目錄；WSL 的家目錄是 /home/帳號，不是 C:\Users\帳號。git clone 下載整個專案，pwd 顯示位置，ls 列出內容。應看到 lessons、demos、scripts、README.md。最後一行是教材版本識別碼，請保留。

已下載過： 不要再次 clone。先進入既有專案查看狀態：

```
cd ~/ClinicalBioinfoCourse
git status --short
```

若顯示自己的修改，先保留並詢問協助；不要執行 reset --hard。確認沒有要保留的未完成修改，再更新：

```
git pull --ff-only
```

--ff-only 只允許快轉更新；若失敗請停下，勿強制覆蓋。舊專案若叫 KCGMH_Cource_Series 也可繼續使用，只要把後面每個 ~/ClinicalBioinfoCourse 換成實際位置，不必搬動或刪除舊資料。

只能用瀏覽器時，在 GitHub 選 Code → Download ZIP，解壓完整內容，放到家目錄並命名 ClinicalBioinfoCourse。ZIP 沒有 Git 紀錄，不能執行 git pull、git rev-parse，請改記下載日期。Windows 可於 Ubuntu 執行 explorer.exe ~ 開啟 Linux 家目錄，再以檔案總管複製解壓資料夾。無網路時請講師經核准管道提供完整副本與版本資訊。

A6. 看懂指令與路徑，再開始分析

Script（腳本）是依序執行的指令檔：.py 用 python3；.sh 用 bash。不要雙擊，也不要貼進 Python 的 >>>。本教材直接呼叫 Bash，不需先對腳本做 chmod +x。

寫法	意思與用途
cd 目錄	切換目前目錄，失敗就先停止，不執行下一行
./ ..	目前目錄 / 上一層；在練習目錄內，../prepare.sh 才會指到上一層腳本
ls / head -n 5 檔案	列出檔案 / 讀前五個，核對位置與欄名
# 說明	註解；不要連終端機提示符號一起複製
> / >>	把輸出寫到檔案並覆蓋 / 附加到檔案末尾
2>&1	把錯誤訊息與一般輸出保存在同一份 log
行尾 \	指令接續下一行，後面不可留空白

路徑有空白時加雙引號，例如 cd "/Users/你的帳號/My Courses/ClinicalBioinfoCourse"。看到 Error、Traceback、command not found 先停止；不能只因為後面有檔案就認為成功。

以下使用新的 practice-local01。專案若已有 practice01，那是既有示範，不要重用。產生器拒絕覆蓋任何已存在目錄；重做請換 practice-local02，並同步修改下一行的 cd。個人 practice-local* 目錄已加入 Git 忽略規則。分析腳本會取代同名輸出，兩次比較應各用一個新目錄。

A7. 第一堂：從合成資料到完整驗證

步驟 1：進入腳本所在位置。 下列從任何目錄都可開始；若你沒有使用預設專案名稱，修改第一行。Mac 新開視窗者先依 A3 設定 PATH。

```
cd ~/ClinicalBioinfoCourse/demos/lesson-01-genomics
pwd
ls generate.py run-array.sh run-sequence.sh verify.py
```

四個檔案都列出才繼續。generate.py 產生資料；run-array.sh 處理 genotype；run-sequence.sh 處理定序檔；verify.py 比較結果與預設答案。

步驟 2：產生自己的練習資料。

```
python3 generate.py practice-local01
cd practice-local01
pwd
ls
```

成功時會印出 Created ...，並說明 40 samples、6000 SNPs 與預期 SNV。目錄中應看到 array.ped、array.map、reference.fa、aligned.sam、review.vcf、intensity.csv。PED / MAP 含 40 個人工樣本與 6,000 個 SNP；SAM 已人工指定比對位置，不需要下載人類 reference 或執行 aligner。

步驟 3：執行 array 流程。 以下在剛建立的 practice-local01 內做：

```
PLINK=plink1.9 bash ../run-array.sh > array.run.log 2>&1
echo $?
tail -n 12 array.run.log
```

PLINK=plink1.9 告訴腳本要呼叫哪個程式，bash 執行上一層的腳本。輸出先存入 array.run.log，所以暫時沒有畫面訊息正常；等待提示符號回來後才輸入下一行。**緊接著的 echo \$? 應為 0**，代表上一命令正常結束；非 0 時先查 log，不要進入下個步驟。tail 顯示 log 最後幾行；完整 log 可用文字編輯器讀取。

腳本依序產生原始 BED/BIM/FAM、篩選前 QC、樣本篩選、位點篩選、LD pruning、親緣、PCA、ROH。它保留中間檔與 PLINK 自己的 .log。請核對：

```
wc -l raw.fam clean.fam raw.bim clean.bim
head -n 5 qc.imiss
head -n 5 qc.lmiss
head -n 3 related.genome
head -n 3 structure.eigenvec
head -n 3 roh.hom
```

wc -l 的行數應依序為 **40、39、6000、5999**；這些檔案沒有標題列，因此可直接當樣本數 / 位點數。

qc.imiss 的 S40 缺失比例約 0.3333，qc.lmiss 的 v1 約 0.275。PCA 產生 39 列，每列 FID、IID 加四個 PC；S01/S02 的 PI_HAT 應接近 1，S03 有 chr1 ROH。PC 正負號及部分 ROH 邊界可能隨工具版本不同，不要要求整份文字逐字一致。

步驟 4：執行定序檔案流程。 不要離開目前目錄：

```
bash ../run-sequence.sh > sequence.run.log 2>&1
echo $?
tail -n 12 sequence.run.log
cat calls.tsv
cat review.tsv
```

同樣要求退出碼 0。流程先為 FASTA 建索引，再把 SAM 轉成排序、索引的 BAM，產生 flagstat 與逐位置深度；接著實際呼叫 BCFtools mpileup / call，最後查詢 VCF。calls.tsv 應有以下一列，欄位間是 tab：

```
chrToy 1000 A C 0/1 40 20,20
```

依序為染色體、位置、REF、ALT、GT、DP、AD：第 1000 位 A→C、雜合、深度 40、REF/ALT 各 20。review.tsv 則有四個另外人工設計的案例，**不是這次 caller 的四筆輸出**。sample.bam、sample.bam.bai、calls.vcf.gz 與 calls.vcf.gz.csi 都應存在。

步驟 5：讓程式自動核對兩條流程。

```
python3 ../verify.py . > verification.txt 2>&1
echo $?
cat verification.txt
```

應為退出碼 0，並看到：

PASS: sizes, missingness, duplicate, PCA, ROH, called SNV and review cases

最後的，是「請核對目前目錄」。這一步同時需要 array 與 sequence 輸出；只做其中一條不能得到完整 PASS。PASS 表示教學範例符合預設，不是臨床流程效能驗證。若有 AssertionError，不要改答案或刪除驗證條件，先保留 log 查明是哪一項不同。

A8. 保存第一堂的可追溯紀錄

仍在自己的練習目錄執行；versions.txt 每次會重新建立，先前紀錄要保留時請先另存。

```
python3 --version > versions.txt
plink1.9 --version >> versions.txt
samtools --version >> versions.txt
bcftools --version >> versions.txt
uname -a >> versions.txt
git rev-parse HEAD > course-commit.txt
```

ZIP 使用者跳過最後一行，改在筆記記錄下載日期。請一起保存原始合成檔、versions.txt、course-commit.txt、兩份 *.run.log、PLINK 的 *.log、verification.txt 與結果，不只交截圖。你應能回答「何時、以哪版教材與工具、對哪份輸入、用什麼參數跑出結果」。

A9. 第一堂常見問題：先查原因，再重跑

現象	先做什麼
command not found	用 command -v python3、command -v samtools、command -v bcftools、command -v plink1.9 查位置；Windows 確認在 Ubuntu、Mac 檢查 Homebrew / 個人 PATH
PLINK 顯示 PuTTY / 2.x、參數不認得	用 plink1.9 --version 確認版本；不要用同名 SSH 軟體或 PLINK 2 代替
Bad CPU type / Exec format error	執行 uname -m 與 file 程式路徑，核對 CPU 與作業系統；不可把 Windows .exe 當 Linux 工具
FileExistsError	產生器保護舊資料；改 practice-local02 並同步改 cd，不要刪舊資料強行重做
No such file / 找不到 array.ped	用 pwd、ls 確認在練習目錄，不是在專案根目錄或腳本目錄
Permission denied	腳本用 bash ../run-array.sh；資料放在自己有寫入權限的家目錄，不用 sudo 跑分析
`\${r}`: command not found	腳本被存成 CRLF；用編輯器改存 UTF-8 / LF，或重新取得未修改的教材，不用 Word 編輯程式
PLINK 提示無 phenotype	本例刻意以 -9 表示未提供，不做疾病關聯分析；仍需確認退出碼 0 和完整 PASS
沒有性染色體可做 sex check	合成資料只有常染色體，屬範例限制
驗證失敗但檔案存在	可能是前次殘留；保留 log，用新練習目錄由產生資料重新做，不混合兩次輸出

安裝時若網路 / TLS / 代理伺服器報錯，請找資訊人員確認核准的網路設定；不要關閉 SSL 驗證。提供協助時請附 OS、CPU、工具版本、pwd、完整命令與第一個錯誤，不需提供病人資料或密碼。

附錄 B：示範範圍與後續學習

本課刻意不安裝或執行平台原始 intensity calling 軟體，不執行人類全基因體 alignment，也不執行正式 CNV / SV caller。這些步驟的原理與輸入需求已在正文說明；實作需另備平台資料、reference、足夠計算資源與驗證過的流程。不能將玩具資料成功運行視為臨床分析驗證。

進一步閱讀：

- [PLINK 1.9](#)：指令、格式與下載。

- [PLINK 基本統計](#)：QC 欄位與限制。
- [SAMtools](#)：比對檔操作。
- [BCFtools](#)：variant calling 與 VCF 查詢。
- [Microsoft WSL](#)：Windows 安裝與權限。

安裝文件核對日期：2026-09-30。三種系統的安裝步驟依官方文件整理；本專案的實際執行驗證環境與結果見 [示範說明](#)，不宣稱已在所有 Windows / Ubuntu 組合測試。