

癌症體細胞基因體分析：從定序證據到可信的候選事件

講師: 奇美醫院精準醫學核心實驗室組長邱家軍

本教材適合臨床醫師、臨床工作者及初次接觸癌症定序分析的研究人員。你不必先會寫程式；可以先閱讀概念與案例，再使用附錄安裝的工具完成練習。

第一堂介紹了基因體資料格式與基本 QC；這一堂進一步處理腫瘤樣本特有的困難：正常細胞混入、不同腫瘤次族群、拷貝數改變，以及檢體處理造成的錯誤。重點是判斷技術證據與分析限制，不是開立處方、致病性分類或正式臨床 actionability 分級。

所有實作使用合成資料。你將實際建立 BAM、查詢 VCF、檢查讀段證據並計算簡化模型；不會將人工案例誤當成真實 somatic caller 的偵測結果，也不會以本練習驗證臨床檢測效能。

閱讀方式與學習目標

建議依序閱讀研究設計、分析原理、實作與案例解析。操作前先完成附錄 A；已完成第一堂安裝者，可直接檢查 Python、SAMtools、BCFtools 是否可用，再安裝 IGV。暫時不能安裝時，可利用文中的輸出表完成判讀。

完成後，你應能：

- 說明 tumor-normal 與 tumor-only 能提供哪些不同的資訊。
- 串接 SNV/indel、CNV、SV 的資料流，區分原始讀段、caller 輸出與 annotation。
- 解釋 VAF 為何不等於腫瘤純度或帶有變異的癌細胞比例。
- 找出低 VAF 候選事件的支持證據與可疑訊號。
- 在分析紀錄中清楚寫出「已觀察到什麼」與「尚不能確定什麼」。

一、研究案例：兩個 5% VAF，能得到相同結論嗎？

你收到一批肺腺癌 FFPE 定序資料，部分樣本有配對正常檢體，部分只有腫瘤。兩個候選位點都得到 400 條有效讀段，其中 20 條支持替代等位基因：

$$\begin{aligned} \text{VAF} &= \text{支持 ALT 的讀段數} / \text{納入計算的讀段總數} \\ &= 20 / 400 = 5\% \end{aligned}$$

第一個位點的 ALT 讀段分布在正、反向比對，變異多位於讀段內部；第二個位點的 ALT 全部來自同一方向，而且集中在讀段末端。你會把兩者都列為相同可信度嗎？

這個問題不能只用「高深度」或「低 VAF」回答。你需要知道樣本來源、讀段品質、比對位置、正常樣本證據、分析模型及篩選規則。

1.1 Somatic 與 germline 是來源概念，不是 VAF 分類

Germline variant（生殖系變異）通常源自生殖細胞或受精卵，存在於多數體細胞；somatic variant（體細胞變異）是在發育或生命歷程中後來產生，可能僅存在於部分組織或細胞。

腫瘤內同時包含 inherited germline 與後天 somatic 變異。不能把 VAF 約 50% 一律當 germline，也不能把低於 50% 一律當 somatic。拷貝數、純度、嵌合與抽樣都會改變比例。

本課的「候選事件」表示值得檢查的分析結果，不等於已確認的腫瘤驅動事件。

1.2 先整理檢體與樣本對照表

欄位	為什麼需要
個案 ID、檢體 ID、定序 sample ID	防止配錯 tumor 與 normal、重複或交換樣本
組織來源、採樣時間、治療前後	同一個案不同時間或病灶可能有不同克隆組成
FFPE / 冷凍、DNA 輸入量與品質	影響片段長度、分子數及損傷背景
病理估計 tumor cellularity	提供純度的初步背景，但不是精確的 DNA purity
Panel / WES / WGS、目標區與版本	決定可分析範圍及結果能否比較
文庫批次、UMI、定序策略	決定 duplicate、consensus 與錯誤處理方式
配對正常來源與可用性	影響 germline 排除、污染判讀與 somatic 推論
Reference、流程版本、資料存放位置	確保結果可重建與回查

Tumor cellularity 是病理觀察中腫瘤細胞所占比例；分析模型中的 purity 則與 DNA 混合及倍體假設相關。兩者可互相參考，但受切片區域、細胞大小及拷貝數等因素影響，不一定完全相等。

二、選擇 tumor-normal 或 tumor-only 分析

2.1 配對正常的作用

Matched normal 是同一個人的非腫瘤參考檢體。它讓你比較「在這個人本來就存在的 allele」與「腫瘤中特別出現的證據」，也有助於排除部分個體特有的比對或序列問題。

設計	需要的輸入	可以增加的資訊	仍然無法保證的事
Tumor-normal	腫瘤與同一人的正常 BAM/CRAM、配對紀錄	個體 germline 證據、腫瘤 / 正常相對支持度	正常覆蓋不足、腫瘤污染正常、正常組織嵌合仍可能干擾
Tumor-only	腫瘤 BAM/CRAM、適合的族群資源與技術背景	依頻率、模型與技術資訊縮小候選集合	無法可靠區分所有 germline 與 somatic 事件

血液不在所有情境下都是理想 normal。血液腫瘤或 clonal hematopoiesis（克隆性造血）可能使血液帶有 somatic 變異；鄰近正常組織也可能有腫瘤污染或場域效應。選擇來源時，要想知道研究疾病與檢體限制。

2.2 正常樣本沒有 ALT，不等於證明不存在

假設正常樣本 200 條有效讀段中沒有 ALT，你只能說「在這些讀段中未觀察到 ALT」。若真正比例很低，仍可能因抽樣沒看到。在簡單獨立抽樣模型下，0 次成功的單側約 95% 上界可用 $3/n$ 近似； $n=200$ 時約 1.5%。這不是檢測方法的臨床偵測極限。

反過來，normal 有少量 ALT 也不必然表示 germline：污染、比對錯誤、嵌合或組織背景都需要納入考慮。判讀應同時比較兩個樣本的品質，而非只比較兩個 VAF。

2.3 PoN 與族群資源不能代替 matched normal

Panel of normals (PoN, 正常樣本面板) 彙整多份正常資料中的技術背景，可協助辨認重複出現的 artifacts。它最好與研究資料的平台、捕捉設計及流程相容，並不等於這位個案的 germline 清單。

Germline population resource 提供族群 allele frequency，協助評估常見 germline 的可能性。但「資料庫沒收錄」不代表 somatic，「資料庫有收錄」也不代表此個案的訊號一定是 germline。稀有性與來源是不同問題。

Tumor-only 結果可能包含尚未辨明的 germline 事件。研究表格應保留不確定性；涉及個案回報時需依既定倫理、同意與專業協作流程處理，而不是由分析人員單憑 VAF 下結論。

三、從 FASTQ 到候選事件：三條相連但不同的分析路徑



3.1 SNV/indel calling 的核心問題

Caller 要比較「這些讀段可能由真實變異產生」與「可能只是定序、比對或其他背景錯誤」的支持程度。腫瘤不適合只用固定二倍體的 0%、50%、100% 期待來分析，因為混合與亞克隆讓 VAF 可以落在更廣的範圍。

以 Mutect2 為例，它透過局部 haplotype assembly 與 somatic 模型偵測短變異；原始輸出還需交由 FilterMutectCalls 等步驟處理。這是一個工具案例，不代表所有流程都必須使用它。[Mutect2 官方文件](#)

Haplotype 是同一條染色體上相連的 allele 組合；局部組裝嘗試重建候選序列，避免僅逐位點數鹼基而忽略 indel 附近的複雜比對。Likelihood 是在特定模型下觀察到這些資料的相對支持度，不是直接的臨床可信度。

3.2 Calling、filtering、annotation 各自回答不同問題

步驟	問題	常見輸出
Calling	哪些位置有足夠證據成為候選變異？	未篩選 VCF、模型統計
Filtering	哪些候選受污染、方向偏差、germline 等因素影響？	FILTER 標記、篩選統計
Annotation	這個變異落在哪個基因、轉錄本或已知條目？	註解 VCF、表格或 MAF
Review / validation	是否有充分而可重現的技術證據？	人工紀錄、追加實驗結果

例如，Mutect2 的方向性資訊可經 LearnReadOrientationModel 建模，與其他資訊一起供 filtering 使用；污染估計也是獨立的證據來源。不要把跑完 caller 當成完成分析，也不要把所有 FILTER 直接刪掉而失去追蹤原因。

[GATK somatic 流程說明](#)

本課實作聚焦於候選事件的證據稽核，不跑完整 Mutect2、人類基因體 alignment 或 CNV/SV caller。因此，不需要下載大型人類 reference、PoN 或安裝整套 GATK；如果後續要執行完整流程，需要另行準備相容資料、環境及驗證方案。

3.3 VCF、MAF 與 segmentation 檔案

VCF 的 CHROM/POS/REF/ALT 定義事件；FORMAT 後的多個樣本欄位提供各自的證據。讀入前先查樣本名稱，不要假設第一欄一定是 tumor。AD 常按 REF、ALT1、ALT2 排列；DP 與 AD 的納入規則依工具而異；AF 可能是模型估計而非單純 AD 比例。

MAF 在此指 **Mutation Annotation Format**，不是第一堂的 minor allele frequency。它常用於癌症 cohort 的變異註解與摘要；欄位可能包含基因、座標、variant classification 與 tumor sample barcode。它通常不保留 BAM 的完整讀段證據，不能代替 VCF/BAM 做 QC。相同縮寫必須依上下文解讀。

Segmentation 檔將連續區域摘要成區段，包含樣本、染色體、起訖位置及區段值。區段值可能是 log2 copy ratio，也可能是絕對 copy number；先查欄位定義。不要把 0.5 的 log2 ratio 讀成「0.5 個拷貝」。

四、腫瘤資料的品質控制：深度之外還要看什麼？

4.1 FFPE、低輸入量與系統性錯誤

FFPE 是 formalin-fixed paraffin-embedded（福馬林固定石蠟包埋）。DNA 可能片段化、交聯或發生損傷；胞嘧啶脫胺可造成 C>T / 互補方向 G>A 類型的假訊號。但 C>T 本身不等於 artifact，真實腫瘤變異也可能是這個替換。

低輸入量代表起始分子有限。反覆定序同一批 PCR 產物可以增加 read depth，卻未必增加獨立證據。系統性錯誤若存在於模板或特定序列環境中，增加深度甚至會使錯誤看起來更穩定。

證據	要問的問題	不能單獨得出的結論
Depth、ALT count	支持讀段多不多？是否來自足夠獨立分子？	高深度一定真實
Base quality	ALT 鹼基本身品質如何？	品質分數能涵蓋全部前處理損傷
Mapping quality	是否可能對到錯誤區域？	MAPQ 高就沒有 reference 或重複區問題
Strand / orientation	ALT 是否集中在特定方向或 read-pair 類型？	正反方向皆有就等於 duplex 驗證
Read position	ALT 是否只出現在末端或 soft clips 附近？	所有末端變異都是錯誤
Local context	周圍是否為 homopolymer、重複序列或 indel？	熱點資料庫可以消除比對疑慮
Normal evidence	normal 深度、ALT、污染是否足夠評估？	normal 0 reads 證明完全不存在

Soft clipping 是比對中未納入對齊的讀段端部；它可來自接頭、比對困難或真實結構變異。需要看群體一致性與區域背景，不是見到 clipping 就刪除。

4.2 Strand、orientation 與 duplex 不要混用

Read strand 指比對到 reference 的正 / 反向。Paired-end orientation 同時涉及配對、read1/read2 與方向；F1R2/F2R1 不是單純的正股 / 反股計數。

Duplex consensus 需要將原始 DNA 雙股的相應分子證據配對整合。一般 BAM 中正反向都有 ALT，不代表已證明原始同一 DNA 分子的雙股都支持。本課合成 BAM 是 single-end，僅示範 strand 與 read-end bias，不示範 F1R2 或 duplex。

UMI (unique molecular identifier) 是在適當文庫流程中加入的分子標記，協助辨識讀段家族與建立 consensus。Raw depth、unique molecule depth、consensus depth 不可混為一談。UMI 也不能自動解決所有前期損傷、標記碰撞或比對錯誤。

4.3 技術可信度與功能重要性分開評估

Hotspot 表示某位置有已知重複出現或功能相關背景；它能增加研究興趣，不能替代原始證據。反之，沒有人報導的新位置也不必然是假陽性。

多個 caller 都報出同一事件也不是獨立實驗驗證：它們可能共用相同比對與錯誤來源。Orthogonal validation (正交驗證) 是以具有不同限制或原理的方式查核；所選方法的靈敏度必須適合目標 VAF，不能假設任何傳統方法都能確認低頻訊號。

五、VAF、純度、拷貝數與克隆性

5.1 從簡單的混合模型開始

假設正常細胞為二倍體，normal 不帶該 ALT；腫瘤細胞在此區域的總拷貝數一致，且各 allele 的定序機會相同。令：

- p：腫瘤純度，腫瘤細胞在混合模型中的比例。

- f : cancer cell fraction (CCF) , 帶有這個變異的腫瘤細胞比例。
- m : 帶變異腫瘤細胞內的 mutant copy 數。
- C : 此區域每個腫瘤細胞的總 copy number 。

$$\text{預期 VAF} = p \times f \times m / [p \times C + (1 - p) \times 2]$$

分子是混合物中的 ALT 拷貝貢獻；分母是全部 allele 拷貝貢獻。這是用來理解影響因素的簡化模型，不是可以不帶前提地反推每個病人的 CCF。若亞克隆有不同 CN、normal 也帶 ALT、倍體不同或存在比對偏差，就需要更完整的模型。

情境	p	f	m	C	預期 VAF
二倍體、clonal heterozygous	0.6	1	1	2	30%
純度低，但仍是 clonal	0.1	1	1	2	5%
純度 60%，一半癌細胞帶變異	0.6	0.5	1	2	15%
總 CN=6，只有一份 mutant copy	0.2	1	1	6	約 7.14%
總 CN=6，有三份 mutant copy	0.2	1	3	6	約 21.43%

Clonal 指在分析解析度下，多數或全部癌細胞帶有事件；subclonal 指只存在於部分癌細胞。上述例子說明：5% VAF 也可能來自 clonal event，不能自動解讀成「只有 5% 癌細胞有變異」。

練習：若觀察到 VAF=15%，除了「純度 60%、CCF 50%」，還有什麼解釋？在同樣二倍體、單份 ALT 假設下，純度 30%、CCF 100% 也能得到相同數字。單一 VAF 無法同時辨認所有未知量。

5.2 拷貝數改變會被低純度稀釋

在以正常二倍體為基準、假設測量無偏差的例子中：

$$\text{copy ratio} = [p \times C + (1 - p) \times 2] / 2$$

$$\text{log2 ratio} = \text{log2}(\text{copy ratio})$$

若腫瘤區域 $C=6$ 、 $p=0.2$ ，混合物的平均拷貝貢獻為 2.8，ratio=1.4，log2 ratio 約 0.485。純腫瘤的 $C=6$ 則為 $\text{log2}(3) \approx 1.585$ 。同一個增益在低純度下看起來較小。

同為腫瘤 $C=6$ ；以下每個 # 約代表 0.1 log2 ratio (示意)

$p=0.2$	#####	0.485
$p=0.6$	#####	1.138
$p=1.0$	#####	1.585

真實 CNV 流程可能以樣本整體或不同倍體基準正規化，不能把上式直接套在所有 segmentation 輸出。Purity/ploidy fitting (純度 / 倍體估計) 會利用全基因體或目標區的 depth、BAF 等資訊共同推估，可能存在多組合理解。

六、實作：建立可回查的腫瘤與正常證據

6.1 準備練習資料

本練習不需要第一堂的輸出。在 Windows 的 WSL Ubuntu、macOS Terminal 或 Linux Terminal 執行以下指令；先完成附錄 A 的安裝與工具檢查。若專案路徑不同，只修改第一行：

```
cd ~/ClinicalBioinfoCourse/demos/lesson-02-somatic
python3 generate.py practice-local01
cd practice-local01
bash ../prepare.sh
```

practice-local01 必須是新資料夾；產生器拒絕覆蓋既有資料。若重做，改成 practice-local02。prepare.sh 重跑會取代同名分析輸出，重要版本應分開保存。

產生器建立 5,000 bp 的人工 contig chrToy、腫瘤 / 正常 SAM、候選 VCF，以及獨立設計的 CN 區段檔。所有 read 位置與候選標記都是人工指定，**不是 aligner 或 somatic caller 的輸出**。真實分子的獨立性、PCR、UMI、paired-end 與 FFPE 化學損傷沒有被模擬。

檔案	用途
reference.fa、.fai	人工 reference 及索引；不可改用 hg19/hg38 開啟本例
tumor.bam、normal.bam 與 .bai	已排序索引、可供 IGV 查看之讀段
candidates.vcf.gz、.tbi	三個人工候選 SNV，含 TUMOR/NORMAL 欄位
candidates.tsv	VCF 查詢結果
tumor.evidence.tsv、normal.evidence.tsv	從 BAM 讀段重新計算的支持證據
copy_number.seg	獨立的 CN 混合模型示意，不是由上述 BAM depth 算出

6.2 理解資料轉換，而不只執行腳本

prepare.sh 先完成下列步驟。你可以在練習資料夾逐行操作，理解輸入與輸出：

```
samtools faidx reference.fa
samtools view -b tumor.sam | samtools sort -o tumor.bam
samtools index tumor.bam
samtools quickcheck -v tumor.bam
samtools flagstat tumor.bam
bcftools query -l candidates.vcf.gz
bcftools view -h candidates.vcf.gz
bcftools query -f '%CHROM\t%POS\t%ID\t%FILTER[\t%SAMPLE:%AD:%DP:%AF]\n' candidates.vcf.gz
```

samtools view -b 轉成 BAM；sort 排序；index 支援區域查詢。quickcheck 主要檢查基本檔案結構，不會證明每條 read 都正確；flagstat 統計比對旗標，不會證明 candidate 可信。

bcftools query -l 顯示樣本名稱；-h 顯示 header。先確認 TUMOR/NORMAL 欄位，再讀各樣本數字。這裡 AF 是產生器指定的比例；真實檔案需依 header 與 caller 文件確認定義。[BCFtools 文件](#)

本例 GT=0/1 是人工表示 REF 與 ALT 同時存在，不能把腫瘤的 0/1 當成「每個腫瘤細胞都是二倍體雜合」。ReviewBias、NormalEvidence 也是教材自訂 FILTER，不是 Mutect2 的正式 filter 名稱。

6.3 直接從讀段核對，不只相信 VCF

```
samtools view tumor.bam | python3 ../audit_reads.py
samtools view normal.bam | python3 ../audit_reads.py
cat tumor.evidence.tsv
cat normal.evidence.tsv
```

audit_reads.py 只支援本例的 150M CIGAR。它排除 unmapped、secondary、QC-fail、duplicate、supplementary flags，並要求 MAPQ≥20、BQ≥20，逐位點計數 T allele。ALT_END5 是 ALT 距任一讀段端部不足 5 個鹼基的數量。這些門檻只為教學；腳本不處理 indel、重疊 read pairs、UMI 或 somatic likelihood，不能取代正式 pileup/caller。

預期的腫瘤輸出：

POS	DEPTH	ALT	VAF	ALT_FORWARD	ALT_REVERSE	ALT_END5
500	400	20	0.05	10	10	0
1500	400	20	0.05	20	0	20
2500	400	200	0.50	100	100	0

正常樣本在 500/1500 各有 200 條讀段、0 ALT；2500 則為 100/200=50%。

請先記錄：哪一個差異被 VAF 隱藏了？答案是 500 與 1500 的方向和讀段位置分布。兩者 DP/AD 完全相同，但 BAM 證據的形狀不同。

6.4 使用 IGV 查看相同證據

IGV (Integrative Genomics Viewer) 能同時顯示 reference、coverage、reads 與候選事件。先依附錄 A 安裝符合 Windows / macOS / Linux 的桌面版，再開啟練習資料：

1. 選擇 Genomes → Load Genome from File，載入 reference.fa；.fai 保留在同一資料夾。不要選人類 hg38。
2. 使用 File → Load from File 載入 tumor.bam、normal.bam 與 candidates.vcf.gz，索引留在各自檔案旁。
3. 搜尋 chrToy:450-550，觀察 tumor 與 normal 的 coverage 和 ALT 支持。
4. 在 alignment 軌道按右鍵，選擇依 read strand 著色；點選 read 查看方向、MAPQ 與位置。不要只依顏色猜 allele。
5. 移至 chrToy:1450-1550，比較 ALT 是否集中在同方向、接近 read ends；再查看 chrToy:2450-2550 的 normal 支持。
6. 載入 copy_number.seg，查看 chrToy:1-5000 的區段訊號。它來自獨立 CN 模型，不應與本例 BAM coverage 當成同一套 CN 證據。

以上操作依 IGV reference 載入說明與 alignment 操作文件整理。不同版本選單文字可能略有差異。

IGV 可能為顯示效能 downsample (抽樣顯示) 讀段；畫面上可見的 read 數不一定等於完整計數。低頻 ALT 不明顯時，查看 coverage 詳細資訊與 downsampling 設定，並用上面的 BAM 計數確認。IGV 是證據瀏覽工具，不是統計驗證或 caller。

若暫時無法使用 IGV，先利用第 6.3 節的讀段統計完成案例；圖形界面則可在安裝完成後補做。

七、三個候選事件的整合判讀

請為每個事件記錄四欄：「目前決策」、「支持證據」、「缺少的資訊」、「下一步」。可使用的決策是：保留為研究候選、需要正交驗證、技術上可疑、需要更多資料。這些標籤不是臨床報告分級。

7.1 事件 A：5% VAF，有正反向讀段支持

在 chrToy:500，tumor=20/400，normal=0/200；ALT 正反方向各 10，未集中在讀段端部。假設真實研究還提供該位置為已知 hotspot 的 annotation，你會如何決定？

參考解析：相對於事件 B，A 有較一致的技術支持，可保留為後續研究候選，但還不能稱為已驗證的 somatic hotspot。需要確認分子獨立性、區域比對背景、PoN、normal 偵測能力與實際流程的驗證範圍。若結果重要或接近已驗證流程的界線，需規劃適當追加驗證。chrToy 本身沒有真實基因或 hotspot 身分，不應拿去查臨床資料庫。

7.2 事件 B：同樣 5%，但集中在同方向及末端

在 chrToy:1500，tumor=20/400，normal=0/200；20 條 ALT 全為同方向，且全在末端。參考解析：標記為技術上可疑，回查讀段與前處理；可考慮重新製備或其他適切方式確認，但不能只說「C>T 所以一定是 FFPE」。本例只是 FFPE-like 的偏差形狀，沒有真的模擬化學損傷。

比較 A/B 的關鍵不是「20 ALT 是否足夠」，而是這些支持是否可能共用同一種錯誤來源。若單純把 VAF≥5% 寫成保留規則，兩者都會留下。

7.3 事件 C：低純度中的 copy-number gain

copy_number.seg 在 chrToy:3000-4000 顯示 log2 ratio 約 0.485。已知合成模型假設 p=0.2、腫瘤 C=6。若不知道模型真值，你能直接把它判為低幅度 gain，或反推一定是六份拷貝嗎？

參考解析：不能僅憑相對 ratio 指定絕對 CN。需核對 purity/ploidy、正規化基準、區段長度、支持區域數、噪音與 BAF。真實資料中「amplification」的操作定義也依研究與方法而異。這裡可以確認模型展示了低純度的稀釋效果，但不是用十個人工 marker 驗證真實 amplification。

7.4 補充對照 D：normal 同樣有 50% VAF

chrToy:2500 在兩個樣本均約 50%。它提供 germline-like 證據，不應只因出現在腫瘤 VCF 就算 somatic。仍需核對正常來源、配對與區域品質；本例的用途是提醒你「候選檔案中的每一列，不都代表癌症特有變異」。

八、CNV、SV 與癌症 cohort 摘要

8.1 CNV：由相對讀深到區段，再到模型

CNV 分析通常先將 coverage 依區域計數，處理 GC、mappability、capture efficiency 等差異，再與正常或參考樣本比較。Segmentation 尋找相鄰區域的共同變化；最後可結合 BAF 與 purity/ploidy 模型，評估 allele-specific CN。

BAF 在此常以 informative heterozygous loci 提供 allele balance 資訊。只有總 copy ratio，不一定能看出 copy-neutral LOH（總拷貝數不變但雜合性喪失）。WES 目標區不連續、捕捉波動較大；不能直接用未校正 depth 比較兩個基因就判定 CNV。

8.2 SV：斷點證據與替代解釋

SV 包括缺失、重複、倒位、易位等。Split read 是一條 read 的不同部分比對到不同位置；discordant read pair 的距離、方向或染色體關係不同於預期。Caller 可整合這些證據、read depth 與局部組裝提出 breakpoint（斷點）候選。

觀察	可能支持	仍需排除
多條 split reads 指向相近位置	一致斷點	重複序列、多重比對、文庫嵌合
多個 pairs 的 mate 在另一染色體	易位候選	系統性 mapping 或文庫問題
區域 depth 下降並伴斷點	缺失候選	捕捉不均、GC 或 reference 差異

本課 single-end 資料沒有這些 paired-end/SV 證據；請勿在 toy BAM 上尋找並不存在的真實結構變異。DNA 的基因重排也不自動證明產生有表現且具功能的 RNA fusion，可能需要 RNA 或其他證據。

8.3 從事件表到 cohort：分母不能消失

做 cohort summary 時，保留 sample ID、事件唯一識別、過濾狀態、有效分析區域與缺失狀態。同一事件若被多個 transcript 註解，不應當成多個獨立變異。

摘要	容易忽略的分母 / 限制
某基因的變異樣本比例	分母應反映該基因可評估的樣本，不是把未覆蓋當陰性
Tumor mutation burden (TMB)	需定義變異集合、有效 Mb、germline/artifact 排除與平台校準
Microsatellite instability (MSI)	需方法與位點模型，不能由幾筆 indel 或高 TMB 直接替代
CNV 頻率	需一致的可評估範圍、純度與事件定義
治療前後 VAF 變化	也受純度、採樣位置、CN 與覆蓋影響，不一定是克隆擴張

液態切片中的 cfDNA（游離 DNA）只有一部分可能來自腫瘤，稱 ctDNA。低比例、分子輸入量及克隆性造血都會影響結果；未偵測到不等於沒有腫瘤變異。這些是分析設計限制，不是單一 VAF 門檻能解決。

九、延伸練習：抽樣能解釋多少，不能解釋多少？

在練習資料夾執行：

```
python3 ../models.py
```

程式只使用 Python 標準函式庫。第一部分重算第五節的 VAF 混合模型；第二部分假設每條 read 相互獨立、真實 ALT 機率为 0.05 且無錯誤，計算至少看到 3 條 ALT 的機率：

```
X ~ Binomial(n, 0.05)
P(X ≥ 3) = 1 - [P(X=0) + P(X=1) + P(X=2)]
```

Depth n	至少 3 條 ALT 的理論機率
30	約 18.78%
100	約 88.17%
400	接近 100%，程式四捨五入顯示 1.000000

這不是臨床 sensitivity 或 limit of detection (LOD)。真實資料有錯誤、分子重複、位置偏差，caller 也不會只用「3 條 ALT」判定。偵測極限需要適當材料、重複實驗與驗證設計；不能用上表直接聲稱「400x 保證測到 5%」。

思考題：事件 B 多定序十倍，能解決原本的末端 / 方向偏差嗎？解析：未必；若反覆放大同一系統性錯誤，更多 reads 不會創造獨立而正確的證據。

十、自我檢核與研究筆記

10.1 先用自己的話回答

1. Tumor-only 加上 PoN，是否等於有 matched normal？
2. 為什麼 VAF=5% 可能是 clonal，而不一定是 subclonal？
3. A/B 同樣 20/400，哪兩項 BAM 證據使判斷不同？
4. 正反向 ALT 都有，能否稱為 duplex consensus？
5. Normal=0/200 能否證明 allele 完全不存在？
6. Copy ratio 與絕對 copy number 的差異是什麼？
7. 為什麼不能把 VCF/MAF 每一列直接當成一個高可信度 somatic event？
8. 為什麼不能把 toy script 成功執行當成臨床流程驗證？

10.2 參考解析

1. 不等於。PoN 是多人的技術背景；matched normal 才是個案本人的參考，但本身仍有侷限。
2. 在二倍體單份 ALT、純度 10% 且全部癌細胞帶變異的模型中，VAF 即為 5%。
3. ALT 的方向與 read-end 分布；B 集中在單方向及端部。
4. 不能。Duplex 需要原始分子雙股的對應證據。
5. 不能。只代表目前讀段中未觀察到，還受抽樣與有效深度影響。
6. Ratio 是相對測量，受基準與混合影響；絕對 CN 需額外模型和證據。
7. 可能含 artifact、germline、低品質、重複 transcript 註解或尚未篩選事件。
8. 本例只有人工讀段與預設候選，未包含真實樣本差異、caller 效能或驗證材料。

10.3 將本課套用到自己的研究

檢查項目	你的筆記 / 待確認事項
Tumor 與 normal 的來源、配對與採樣時間	
檢體處理、DNA 輸入量、純度與批次	
平台、目標區域、reference 與版本	
獨立分子 / UMI / consensus 的定義	
Somatic calling、filtering 與背景資源	
候選事件的 read-level 證據	
CN、purity/ploidy 的假設與不確定性	
未評估區域、排除理由與驗證需求	

建議保留原始候選與篩選後集合、FILTER 原因、人工觀察、工具版本、資料來源及後續決策。將「技術上可信」、「生物學上有興趣」與「足以支持臨床行動」分開紀錄。

十一、名詞速查

名詞	本課用法
Somatic / germline	後天體細胞來源 / 生殖系來源，不是 VAF 高低分類
Matched normal / tumor-only	同人正常參考 / 只有腫瘤資料的分析設計
VAF / CCF	allele 支持比例 / 帶變異的癌細胞比例，兩者不同
Purity / ploidy	腫瘤混合比例 / 染色體組或拷貝數背景
FFPE / artifact	固定包埋檢體 / 技術形成的非真實候選訊號
UMI / consensus	分子識別標記 / 整合同分子讀段所形成的序列
PoN	多份正常資料建立的背景資源
Strand / orientation	比對正反方向 / 包含 read-pair 結構的方向資訊
CNV / SV	拷貝數變化 / 結構變異，部分事件同時屬兩者
Segmentation / BAF	將訊號整合為連續區段 / 相對 allele 訊號或比例資訊
MAF	此處為 Mutation Annotation Format，不是 minor allele frequency
TMB / MSI	腫瘤突變負荷 / 微衛星不穩定，各需合適分析方法
cfDNA / ctDNA	游離 DNA / 其中腫瘤來源的 DNA
Orthogonal validation	用具有不同限制或原理的方法補充驗證

附錄 A：依作業系統安裝，到第一次成功執行

A1. 選擇操作路線與必要工具

依序完成「選作業系統 → 安裝工具 → 下載完整專案 → 產生自己的練習資料 → 執行腳本 → 核對結果」。只閱讀自己系統的安裝分支，再接共同步驟。所有資料均為合成教學資料，不要把病人資料放進這個公開專案。

電腦	安裝路線	之後在哪裡輸入指令
Windows 11、Intel / AMD 64-bit	A2：WSL2 + Ubuntu 24.04	Ubuntu；只有安裝 WSL 使用 PowerShell
macOS、Apple Silicon 或 Intel	A3：Homebrew + 官方 PLINK 1.9	Terminal（終端機）
Linux、Ubuntu 24.04 / 相容 Debian 系統	A4：系統套件管理員	Linux Terminal
Windows ARM / Linux ARM64、其他 Linux	先看 A4 相容性限制	不可直接假設 x86_64 執行檔可用

Windows 可由「設定 → 系統 → 關於 → 系統類型」確認處理器；Mac 可由「蘋果選單 → 關於這台 Mac」確認晶片。Linux / WSL 的 `uname -m` 若顯示 `x86_64`，是 Intel / AMD 64-bit；`aarch64` 是 ARM64。Mac 原生 Apple Silicon 終端機通常顯示 `arm64`。

工具	本次用途	哪堂需要
Git	下載完整教材，記錄教材版本	兩堂
Python 3.8 以上	產生合成資料、自動核對；只用標準函式庫	兩堂
Bash	依序執行 .sh 腳本、連接工具	兩堂
SAMtools	SAM/BAM 轉換、排序、索引與讀段統計	兩堂
BCFtools	VCF 處理；第一堂另做小型 variant calling	兩堂
PLINK 1.9	Genotype QC、PCA、親緣與 ROH	第一堂
IGV Desktop	圖形化查看 reference、BAM、VCF、SEG	第二堂的視覺核對

不需 R、Docker、Conda、GPU、付費軟體或額外 Python 套件。FastQC、aligner、Mutect2 在概念部分介紹，但本次腳本沒有呼叫它們，不必額外安裝。第二堂不使用第一堂的輸出，可以單獨操作。

請為 WSL / 開發工具預留數 GB 磁碟空間並確認能連線至官方下載站與 GitHub；合成資料本身很小。安裝可能需要管理員權限，分析則不需要 sudo。院內電腦請先取得核准；不能安裝時請資訊人員提供合規環境，勿停用防護或繞過權限。

A2. Windows : WSL2 + Ubuntu

步驟 1：安裝 Linux 環境。 WSL (Windows Subsystem for Linux) 讓 Windows 使用 Linux 工具。本路線選 Windows 11 與 Ubuntu 24.04 LTS。Microsoft 簡易指令也支援 Windows 10 2004、build 19041 以上；作業系統維護狀態與院內政策另行確認。[Microsoft 安裝說明](#)

在開始選單搜尋 PowerShell，按右鍵「以系統管理員身分執行」，先查已安裝及可下載的發行版：

```
wsl --list --verbose
wsl --list --online
```

尚未安裝者，確認線上清單有 Ubuntu-24.04 後執行：

```
wsl --install -d Ubuntu-24.04
```

依提示重新開機，從開始選單開啟 Ubuntu 24.04，建立 Linux 帳號與密碼；它們可以不同於 Windows 帳號。輸入密碼不顯示字元是正常現象。已有可用 Ubuntu 不必重裝，尤其不要使用 wsl --unregister，這會刪除該環境與資料。

步驟 2：確認 WSL2。 在 PowerShell 再執行 wsl --list --verbose，Ubuntu 的 VERSION 應為 2。若為 1，請先確認硬體虛擬化與政策允許，再執行：

```
wsl --set-version Ubuntu-24.04 2
```

發行版名稱必須與清單一致；若清單顯示 Ubuntu，就改用 Ubuntu。

步驟 3：改在 Ubuntu 視窗安裝工具。 PowerShell 常見提示為 PS C:\...\>；Ubuntu 通常為 使用者@電腦:~\$。下面指令不是貼在 PowerShell、CMD、Git Bash 或 Python 的 >>>。

```
uname -m
sudo apt update
sudo apt install -y git python3 samtools bcftools
```

apt update 更新套件清單，apt install 安裝工具；sudo 要求剛設定的 Linux 密碼。第一堂另外安裝：

```
sudo apt install -y plink1.9
plink1.9 --version
```

PLINK 指令以 Ubuntu 24.04 的 x86_64 為主要路線；ARM 電腦或找不到套件請看 A4。不要改裝 PLINK 2 當成同一工具。完成後跳到 A5，不需再裝 Windows 版 Python / SAMtools。

A3. macOS : Homebrew + PLINK 1.9

步驟 1：打開 Terminal。 按 Command+空白鍵，搜尋 Terminal，再查看系統：

```
sw_vers
uname -m
```

先核對 [Homebrew 支援範圍](#)。舊 macOS / Intel Mac 的支援程度不同，安裝若提示不支援，應請資訊人員安排相容工具或核准的 Linux 環境，勿強行覆寫系統。

步驟 2：安裝 Homebrew。 它是管理命令列軟體的工具。先執行 `brew --version`；已有版本就跳過重裝。否則前往 [Homebrew 官網](#)，確認來源與權限後，在 Terminal 執行官方安裝指令：

```
/bin/bash -c "$(curl -fsSL https://raw.githubusercontent.com/Homebrew/install/HEAD/install.sh)"
```

這行會下載並執行安裝程式，請閱讀提示再同意。若要求 Command Line Tools，依提示完成，或執行 `xcode-select --install` 並於系統視窗安裝；不用下載完整 Xcode。

安裝結束，照畫面 **Next steps** 設定 `shellenv`，讓終端機找到 `brew`。若目前視窗仍找不到，Apple Silicon 的標準安裝位置可執行：

```
eval "$(/opt/homebrew/bin/brew shellenv)"
```

Intel Mac 的標準位置則用：

```
eval "$(/usr/local/bin/brew shellenv)"
```

只選符合安裝位置的一段。`eval` 在此載入 Homebrew 的環境設定；這一行僅影響目前視窗，仍應依 Next steps 完成啟動設定。再用 `brew --version` 確認。

步驟 3：安裝兩堂共用工具。

```
brew install git python samtools bcftools
```

`python` 是套件名稱，執行時仍叫 `python3`。不要在 `brew install` 前加 `sudo`。套件名稱見 [SAMtools formula](#) 與 [BCFtools formula](#)。

步驟 4：第一堂另裝 PLINK。 第二堂可以跳過。於 [PLINK 1.9 官方頁](#)選 macOS 64-bit stable，不要選 PLINK 2。以下固定使用 2026-09-27 版本；本次實際檢查它是包含 x86_64 與 arm64 的 Universal binary，Intel 與 Apple Silicon 可用同一檔案。

```
mkdir -p "$HOME/bioinfo-tools/plink19-20260927"
cd "$HOME/bioinfo-tools/plink19-20260927"
curl -fL \
  https://s3.amazonaws.com/plink1-assets/plink_mac_20260927.zip \
  -o plink.zip
unzip -n plink.zip
file plink
./plink --version
```

`mkdir -p` 建立工具目錄；`curl -fL` 下載並在 HTTP 錯誤時失敗；`unzip -n` 解壓但不覆蓋既有檔案；`file` 顯示程式架構。每一步無錯誤才繼續。版本應顯示 PLINK v1.9.0。本例不用一律加裝 Rosetta；如果另用 Intel-only 舊版，才需核對 [Apple Rosetta 說明](#)。

為了與 Ubuntu 一樣使用 `plink1.9` 命令，把已確認來源的程式放到個人工具目錄。若目的地已有其他版本，先備份或改名，不要直接取代。

```
mkdir -p "$HOME/.local/bin"
install -m 755 ./plink "$HOME/.local/bin/plink1.9"
export PATH="$HOME/.local/bin:$PATH"
plink1.9 --version
```

`install -m 755` 複製並賦予執行權限；PATH 是終端機搜尋程式的目錄清單。`export` 只在目前視窗與子程式有效，**每次新開 Terminal 執行第一堂前，再執行 `export PATH="$HOME/.local/bin:$PATH"`**。熟悉 shell 者可自行寫入個人啟動檔。不要只設定 alias，因為子腳本未必能使用。

若 macOS 阻擋下載程式，確認官方來源後依「隱私權與安全性」提示或洽資訊人員處理，不要全域停用 Gatekeeper。完成後前往 A5。

A4. Linux：套件安裝與相容性

Linux 不需安裝 WSL 或 Homebrew。打開 Terminal，確認發行版與 CPU：

```
cat /etc/os-release
uname -m
```

以下以 **Ubuntu 24.04 LTS**、**x86_64** 為基準。Debian 可使用相同套件管理命令，但套件版本與架構須另確認。Fedora、Rocky、Arch 不是 apt 系統，請由資訊人員用該系統的套件管理方式提供 A1 工具，再從 A5 檢查，不要直接照貼 apt。

```
sudo apt update
sudo apt install -y git python3 samtools bcftools
```

第一堂另外執行：

```
sudo apt install -y plink1.9
plink1.9 --version
```

若 Unable to locate package plink1.9，先查拼字、apt update 是否成功及發行版。Ubuntu 的套件位於 **universe**；只有院內允許新增來源時才執行：

```
sudo apt install -y software-properties-common
sudo add-apt-repository universe
sudo apt update
sudo apt install -y plink1.9
```

這段新增來源只適用 Ubuntu，不適用 Debian。伺服器沒有 sudo 者，請管理員安裝或啟用既有環境，不要修改系統權限。

ARM64 限制： [Ubuntu 24.04 的 plink1.9 套件頁](#)目前沒有 ARM64 套件。Windows ARM 的 WSL、ARM Linux 不應下載 x86_64 程式硬跑。若 Python、SAMtools、BCFtools 可用，仍可完成第一堂定序部分及第二堂命令列練習；array 部分請資訊人員提供經確認的 PLINK 1.9 ARM 編譯版，或改用核准的 x86_64 Ubuntu 電腦 / 伺服器。本教材不宣稱已驗證 ARM Linux 的 array 流程。使用遠端主機時，安裝與腳本都在遠端執行，供 IGV 使用的結果需另下載到桌面電腦。

A5. 共同步驟：確認工具與下載專案

Windows 在 Ubuntu，macOS / Linux 在 Terminal 執行。後文 .sh 都用 bash 呼叫，因此 Mac 預設是 zsh 也能操作。

```
git --version
python3 --version
bash --version
samtools --version
bcftools --version
```

每行應印出版本，不是 command not found；SAMtools / BCFtools 顯示多行編譯資訊正常。Python 至少 3.8，因第二堂使用 math.comb。第一堂加跑 `plink1.9 --version`，確認是 PLINK 1.9 / 1.90 系列，不是 2.x 或 PuTTY 的同名連線工具。

第一次下載： 假設家目錄尚無 ClinicalBioinfoCourse 資料夾：

```
cd ~
git clone https://github.com/godkin1211/ClinicalBioinfoCourse.git
cd ClinicalBioinfoCourse
pwd
ls
git rev-parse --short HEAD
```

公開專案不需 GitHub 帳號或 token。cd ~ 回到目前使用者的家目錄；WSL 的家目錄是 /home/帳號，不是 C:\Users\帳號。git clone 下載整個專案，pwd 顯示位置，ls 列出內容。應看到 lessons、demos、scripts、README.md。最後一行是教材版本識別碼，請保留。

已下載過： 不要再次 clone。先進入既有專案查看狀態：

```
cd ~/ClinicalBioinfoCourse
git status --short
```

若顯示自己的修改，先保留並詢問協助；不要執行 reset --hard。確認沒有要保留的未完成修改，再更新：

```
git pull --ff-only
```

--ff-only 只允許快轉更新；若失敗請停下，勿強制覆蓋。舊專案若叫 KCGMH_Cource_Series 也可繼續使用，只要把後面每個 ~/ClinicalBioinfoCourse 換成實際位置，不必搬動或刪除舊資料。

只能用瀏覽器時，在 GitHub 選 Code → Download ZIP，解壓完整內容，放到家目錄並命名 ClinicalBioinfoCourse。ZIP 沒有 Git 紀錄，不能執行 git pull、git rev-parse，請改記下載日期。Windows 可於 Ubuntu 執行 explorer.exe ~ 開啟 Linux 家目錄，再以檔案總管複製解壓資料夾。無網路時請講師經核准管道提供完整副本與版本資訊。

A6. 看懂指令與路徑，再開始分析

Script（腳本）是依序執行的指令檔：.py 用 python3；.sh 用 bash。不要雙擊，也不要貼進 Python 的 >>>。本教材直接呼叫 Bash，不需先對腳本做 chmod +x。

寫法	意思與用途
cd 目錄	切換目前目錄，失敗就先停止，不執行下一行
./ ..	目前目錄 / 上一層；在練習目錄內，../prepare.sh 才會指到上一層腳本
ls / head -n 5 檔案	列出檔案 / 讀前五行，核對位置與欄名
# 說明	註解；不要連終端機提示符號一起複製
> / >>	把輸出寫到檔案並覆蓋 / 附加到檔案末尾
2>&1	把錯誤訊息與一般輸出保存在同一份 log
行尾 \	指令接續下一行，後面不可留空白

路徑有空白時加雙引號，例如 cd "/Users/你的帳號/My Courses/ClinicalBioinfoCourse"。看到 Error、Traceback、command not found 先停止；不能只因為後面有檔案就認為成功。

以下使用新的 practice-local01。專案若已有 practice01，那是既有示範，不要重用。產生器拒絕覆蓋任何已存在目錄；重做請換 practice-local02，並同步修改下一行的 cd。個人 practice-local* 目錄已加入 Git 忽略規則。分析腳本會取代同名輸出，兩次比較應各用一個新目錄。

A7. 第二堂：準備 BAM、檢查證據、驗證結果

步驟 1： 進入本堂腳本目錄。不需要第一堂的輸出或 PLINK：

```
cd ~/ClinicalBioinfoCourse/demos/lesson-02-somatic
pwd
ls generate.py prepare.sh audit_reads.py verify.py models.py
```

五個檔案都列出才繼續。generate.py 造出合成資料；prepare.sh 轉檔與索引；audit_reads.py 從讀段重算證據；verify.py 檢查答案；models.py 列出 VAF、純度、CN 與抽樣的簡化模型。

步驟 2：產生新練習資料。

```
python3 generate.py practice-local01
cd practice-local01
pwd
ls
```

成功時會印出 Created ... 與 A/B、D 的預期比例。應出現 reference.fa、tumor.sam、normal.sam、candidates.vcf、copy_number.seg。第一堂與第二堂各自目錄下同名的 practice-local01 是不同資料夾，內容不可互換。

這些 SAM 的位置、VCF 的候選與 FILTER 都是人工設定。prepare.sh 不執行 aligner、Mutect2 或 CN caller；SEG 來自獨立的模型，不能當成 BAM 深度推估結果。

步驟 3：執行資料整理。

```
bash ../prepare.sh > prepare.run.log 2>&1
echo $?
tail -n 12 prepare.run.log
ls *.bam *.bai *.tbi *.tsv
```

bash 執行上一層的腳本，> prepare.run.log 2>&1 保留一般與錯誤輸出。等待提示符號回來後，緊接的 echo \$? 應為 0；非 0 先停下查 log。成功時 log 可能很短，不能用文字多寡判斷成敗。

腳本為 reference 建 .fai，把兩份 SAM 轉成排序 BAM、建立 .bai、執行 quickcheck 與 flagstat；再壓縮 VCF、建立 .tbi、查詢欄位，最後把 BAM 讀段交給 audit_reads.py 重新統計證據。

步驟 4：確認檔案可讀及樣本正確。

```
samtools quickcheck -v tumor.bam normal.bam
echo $?
bcftools query -l candidates.vcf.gz
cat tumor.evidence.tsv
cat normal.evidence.tsv
cat candidates.tsv
```

quickcheck 正常時通常沒有輸出且退出碼 0；它檢查基本結構，不代表每條 read 都可信。VCF 樣本名稱依序應是 TUMOR、NORMAL，不要因欄位位置就自行猜測。

位點	腫瘤 ALT / 深度	正向 / 反向 ALT	端部 ALT	正常 ALT / 深度
chrToy:500	20 / 400	10 / 10	0	0 / 200
chrToy:1500	20 / 400	20 / 0	20	0 / 200
chrToy:2500	200 / 400	100 / 100	0	100 / 200

前三列都應出現在證據表。500 與 1500 都是 VAF 5%，但後者的 ALT 完全單向且接近讀段末端。這是教材設計的可疑模式，不應只憑方向偏差就宣告真偽。正常樣本在 2500 的支持則提醒你注意 germline / normal evidence，而非把腫瘤裡所有變異都當 somatic。

步驟 5：執行自動核對。

```
python3 ../verify.py . > verification.txt 2>&1
echo $?
cat verification.txt
```

應為退出碼 0，並顯示以下完整訊息（畫面自動換行正常）：

```
PASS: BAM-derived counts, bias patterns, VCF samples/flags, CN/VAF models, indexed artifacts
```

。指目前目錄。程式確認 BAM 衍生計數、方向 / 端部模式、VCF 樣本與標記、模型及索引檔；**不是**驗證 somatic caller 的敏感度或臨床效能。

步驟 6：執行模型與保存紀錄。

```
python3 ../models.py > models.txt
echo $?
cat models.txt
python3 --version > versions.txt
samtools --version >> versions.txt
bcftools --version >> versions.txt
uname -a >> versions.txt
git rev-parse HEAD > course-commit.txt
```

models.py 只用 Python 標準函式庫，不需 pip。low_purity 的預期 VAF 為 0.050000，gain_one_mutant_copy 為 0.071429，CN6 purity=0.2 的 log2ratio 約 0.485427；這些是條件指定後的計算，不是從病人資料反推的估計。ZIP 使用者跳過 Git 一行，另記下載日期。保留輸入、版本、prepare.run.log、verification.txt、models.txt 及所有結果。

A8. 三種系統的 IGV 安裝與啟動

IGV 是桌面圖形程式，不是另一個 caller。命令列 PASS 與 IGV 載入成功是兩個不同檢查；GUI 暫不可用時可先完成證據表判讀。

到 [IGV 官方下載頁](#) 選與作業系統、CPU 相符的穩定版，優先使用 **包含 Java runtime** 的套件。不要為本課改裝 beta；若下載不含 Java 的版本，按當版需求另備 Java。核對時官方說明為 IGV 2.19.1 起需 Java 21 以上；下載頁改版時以當版文件為準。

Windows： 在 Windows 瀏覽器下載 Windows 安裝包，依精靈選目的地並完成，從開始選單開啟 IGV。不是在 Ubuntu 執行 .exe。若電腦是 Windows ARM，先確認當版 Windows 套件與 Java 支援該架構，不把 x64 支援視為 ARM 原生支援。院內禁止安裝時請資訊人員部署。

macOS： 在下載頁選符合 Apple Silicon / Intel 的 Mac app，開啟下載的封裝；若為 ZIP 先解壓，把 IGV.app 拖到 Applications，再從 Applications 啟動。若出現安全提示，確認來源後依系統允許的操作或洽資訊人員處理，不要全域關閉安全機制。

Linux 桌面： x86_64 使用官方 Linux 套件（包含 Java），於檔案管理員解壓，開啟解壓目錄中的終端機，確認 igv.sh 存在，再執行：

```
pwd
ls igv.sh
bash igv.sh
```

需有可用的桌面顯示環境。官方 Linux 包附的是 x64 Java；ARM64 不可直接使用，應選「Command line IGV for all platforms」並由資訊人員安裝相容架構的 Java 21 以上，確認 java -version 後再啟動。這個名稱仍是啟動桌面 GUI 的方式，不代表能在沒有顯示環境的 SSH 視窗直接顯示。遠端 / 無桌面的伺服器可完成命令列分析，再把本課合成結果下載到本機桌面 IGV。

啟動後於 About 對話框（依系統在 Help 或應用程式選單）記下版本。下一步不需下載 hg38；使用本課 chrToy。

A9. 把結果交給 IGV，完成視覺核對

步驟 1：找到結果資料夾。 在目前練習目錄執行 pwd。Mac 可用 open . 在 Finder 開啟；Linux 桌面可用檔案管理員前往該路徑；Windows 在 Ubuntu 用：

```
explorer.exe .
```

它會用 Windows 檔案總管開啟 WSL 的目前資料夾。若 IGV 無法直接讀 WSL 路徑，透過檔案總管把下面整組合成檔案複製到一個新的 Windows 資料夾，例如 Documents\ClinicalBioinfoLesson02，不要只複製 BAM。不要在分析尚未結束時複製。

一起保留的檔案	理由
reference.fa、reference.fa.fai	人工 reference 與位置索引
tumor.bam、tumor.bam.bai	腫瘤讀段與索引
normal.bam、normal.bam.bai	正常讀段與索引
candidates.vcf.gz、candidates.vcf.gz.tbi	壓縮候選檔與 tabix 索引
copy_number.seg	人工設計的 CN 區段示意

這裡總共 9 個檔案。保持檔名相配；不要單獨改名 tumor.bam 卻不改 tumor.bam.bai。vcf.gz 不需自行解壓。

步驟 2：載入正確 reference。 在 IGV 選 Genomes → Load Genome from File，選 reference.fa。同目錄保留 .fai；成功時應能選到 chrToy，不是 chr1 或 hg38。如果 GUI 選單文字略不同，以當版 reference 載入功能為準。

步驟 3：載入結果。 選 File → Load from File，載入 tumor.bam、normal.bam、candidates.vcf.gz、copy_number.seg。索引不需當成獨立軌道載入，但必須在旁邊。應出現兩個 alignment / coverage 軌道、候選軌道與 CN 區段。

步驟 4：逐位點查看。 搜尋 chrToy:450-550 並按 Enter。放大到可見鹼基，點選 / 移到 coverage 及 read 以查看實際數值；在 alignment 軌道右鍵選 Color alignments by → Read strand（名稱依版本可能略異）。不要把不同顯示配色直接當作固定生物學意義。

接著查 chrToy:1450-1550，比較 ALT 方向與讀段末端位置；查 chrToy:2450-2550，看 normal 也支持 ALT。最後查 chrToy:1-5000，應見 3000-4000 的 SEG 約 0.485427；該模型與本例 BAM depth 獨立，不要把它說成同一份資料算出的 CN 結果。

步驟 5：定義完成。 你應能指出：500 與 1500 同為 5% VAF 但支持模式不同；2500 有 normal evidence；CN 軌道是獨立示意。若畫面 read 數比表格少，先檢查 downsampling（抽樣顯示）設定，回查完整 BAM 統計；螢幕可見數量不是深度的唯一依據。保存座標與判讀筆記，截圖只能補充，不能取代 BAM / VCF 與執行紀錄。

A10. 第二堂常見問題

現象	檢查與處理
command not found	先查是否在正確終端機，再以 command -v python3、command -v samtools、command -v bcftools 找路徑
FileExistsError	改 practice-local02，並同步更改 cd；不要覆蓋既有練習
找不到 reference.fa / ../prepare.sh	用 pwd、ls 確認正在第二堂的練習子目錄
\$'\r': command not found	腳本換行格式錯誤；用文字編輯器存為 UTF-8 / LF，或重新取得教材
沒有 BAM 或索引	先查 prepare.run.log 的第一個錯誤，不直接跳到 IGV
math.comb 不存在	檢查 Python 是否至少 3.8、python3 是否指到舊環境
程式說只支援 150M	可能用了其他資料；本例不是通用 pileup 工具
IGV 空白 / 找不到 chrToy	先載入本課 reference，再放大到指定座標，不用 hg19/hg38
找不到 index	核對完整 9 檔、同目錄與檔名；索引要配對本次 BAM / VCF
IGV 不能啟動 / Java 錯誤	確認套件的 OS、CPU、Java 版本；Linux 確認桌面環境；優先用官方附 Java 套件
顯示 read 數不足	檢查 downsampling 與縮放，用 *.evidence.tsv 比較完整計數
沒有 sudo / 管理員權限	使用資訊人員核准環境；可以先做輸出表判讀，不繞過政策

求助請提供系統 / CPU、版本、pwd、完整命令、第一個錯誤及合成資料的 log；不要提供病人資料、token 或密碼。每次重跑若改參數，另建新的練習目錄保存差異。

附錄 B：實作邊界與延伸閱讀

本教材的 SAM、VCF 與 CN 區段都是人工設計；BAM 證據統計與模型計算會實際執行，但不代表已完成 somatic discovery。IGV 用於視覺核對，與正交驗證不同。欲處理真實資料，需依研究目標選定相容、可重現且經過適當驗證的流程。

- [Mutect2](#)：somatic short-variant calling 的工具案例。
- [GATK somatic workflow](#)：方向性、污染與過濾步驟。
- [BCFtools](#)：VCF 查詢與格式操作。
- [IGV alignment 文件](#)：讀段與 coverage 的顯示限制。
- [IGV paired-end 文件](#)：配對方向與結構變異證據。

安裝文件核對日期：2026-09-30。實際測試環境、驗證內容與未測試項目見[第二堂示範說明](#)。