

癌症體細胞基因體分析：從定序證據到可信的候選事件

講師: OO 醫院精準醫學核心實驗室組長邱 XX

本教材適合臨床醫師、臨床工作者及初次接觸癌症定序分析的研究人員。你不必先會寫程式；可以先閱讀概念與案例，再使用附錄安裝的工具完成練習。

第一堂介紹了基因體資料格式與基本 QC；這一堂進一步處理腫瘤樣本特有的困難：正常細胞混入、不同腫瘤次族群、拷貝數改變，以及檢體處理造成的錯誤。重點是判斷技術證據與分析限制，不是開立處方、致病性分類或正式臨床 actionability 分級。

所有實作使用合成資料。你將實際建立 BAM、查詢 VCF、檢查讀段證據並計算簡化模型；不會將人工案例誤當成真實 somatic caller 的偵測結果，也不會以本練習驗證臨床檢測效能。

閱讀方式與學習目標

建議依序閱讀研究設計、分析原理、實作與案例解析。操作前先完成附錄 A；已完成第一堂安裝者，可直接檢查 Python、SAMtools、BCFtools 是否可用，再安裝 IGV。暫時不能安裝時，可利用文中的輸出表完成判讀。

完成後，你應能：

- 說明 tumor-normal 與 tumor-only 能提供哪些不同的資訊。
- 串接 SNV/indel、CNV、SV 的資料流，區分原始讀段、caller 輸出與 annotation。
- 解釋 VAF 為何不等於腫瘤純度或帶有變異的癌細胞比例。
- 找出低 VAF 候選事件的支持證據與可疑訊號。
- 在分析紀錄中清楚寫出「已觀察到什麼」與「尚不能確定什麼」。

一、研究案例：兩個 5% VAF，能得到相同結論嗎？

你收到一批肺腺癌 FFPE 定序資料，部分樣本有配對正常檢體，部分只有腫瘤。兩個候選位點都得到 400 條有效讀段，其中 20 條支持替代等位基因：

$$\begin{aligned} \text{VAF} &= \text{支持 ALT 的讀段數} / \text{納入計算的讀段總數} \\ &= 20 / 400 = 5\% \end{aligned}$$

第一個位點的 ALT 讀段分布在正、反向比對，變異多位於讀段內部；第二個位點的 ALT 全部來自同一方向，而且集中在讀段末端。你會把兩者都列為相同可信度嗎？

這個問題不能只用「高深度」或「低 VAF」回答。你需要知道樣本來源、讀段品質、比對位置、正常樣本證據、分析模型及篩選規則。

1.1 Somatic 與 germline 是來源概念，不是 VAF 分類

Germline variant（生殖系變異）通常源自生殖細胞或受精卵，存在於多數體細胞；somatic variant（體細胞變異）是在發育或生命歷程中後來產生，可能僅存在於部分組織或細胞。

腫瘤內同時包含 inherited germline 與後天 somatic 變異。不能把 VAF 約 50% 一律當 germline，也不能把低於 50% 一律當 somatic。拷貝數、純度、嵌合與抽樣都會改變比例。

本課的「候選事件」表示值得檢查的分析結果，不等於已確認的腫瘤驅動事件。

1.2 先整理檢體與樣本對照表

欄位	為什麼需要
個案 ID、檢體 ID、定序 sample ID	防止配錯 tumor 與 normal、重複或交換樣本
組織來源、採樣時間、治療前後	同一個案不同時間或病灶可能有不同克隆組成
FFPE / 冷凍、DNA 輸入量與品質	影響片段長度、分子數及損傷背景
病理估計 tumor cellularity	提供純度的初步背景，但不是精確的 DNA purity
Panel / WES / WGS、目標區與版本	決定可分析範圍及結果能否比較
文庫批次、UMI、定序策略	決定 duplicate、consensus 與錯誤處理方式
配對正常來源與可用性	影響 germline 排除、污染判讀與 somatic 推論
Reference、流程版本、資料存放位置	確保結果可重建與回查

Tumor cellularity 是病理觀察中腫瘤細胞所占比例；分析模型中的 purity 則與 DNA 混合及倍體假設相關。兩者可互相參考，但受切片區域、細胞大小及拷貝數等因素影響，不一定完全相等。

二、選擇 tumor-normal 或 tumor-only 分析

2.1 配對正常的作用

Matched normal 是同一個人的非腫瘤參考檢體。它讓你比較「在這個人本來就存在的 allele」與「腫瘤中特別出現的證據」，也有助於排除部分個體特有的比對或序列問題。

設計	需要的輸入	可以增加的資訊	仍然無法保證的事
Tumor-normal	腫瘤與同一人的正常 BAM/CRAM、配對紀錄	個體 germline 證據、腫瘤 / 正常相對支持度	正常覆蓋不足、腫瘤污染正常、正常組織嵌合仍可能干擾
Tumor-only	腫瘤 BAM/CRAM、適合的族群資源與技術背景	依頻率、模型與技術資訊縮小候選集合	無法可靠區分所有 germline 與 somatic 事件

血液不在所有情境下都是理想 normal。血液腫瘤或 clonal hematopoiesis（克隆性造血）可能使血液帶有 somatic 變異；鄰近正常組織也可能有腫瘤污染或場域效應。選擇來源時，要先知道研究疾病與檢體限制。

2.2 正常樣本沒有 ALT，不等於證明不存在

假設正常樣本 200 條有效讀段中沒有 ALT，你只能說「在這些讀段中未觀察到 ALT」。若真正比例很低，仍可能因抽樣沒看到。在簡單獨立抽樣模型下，0 次成功的單側約 95% 上界可用 $3/n$ 近似； $n=200$ 時約 1.5%。這不是檢測方法的臨床偵測極限。

反過來，normal 有少量 ALT 也不必然表示 germline：污染、比對錯誤、嵌合或組織背景都需要納入考慮。判讀應同時比較兩個樣本的品質，而非只比較兩個 VAF。

2.3 PoN 與族群資源不能代替 matched normal

Panel of normals (PoN, 正常樣本面板) 彙整多份正常資料中的技術背景，可協助辨認重複出現的 artifacts。它最好與研究資料的平台、捕捉設計及流程相容，並不等於這位個案的 germline 清單。

Germline population resource 提供族群 allele frequency，協助評估常見 germline 的可能性。但「資料庫沒收錄」不代表 somatic，「資料庫有收錄」也不代表此個案的訊號一定是 germline。稀有性與來源是不同問題。

Tumor-only 結果可能包含尚未辨明的 germline 事件。研究表格應保留不確定性；涉及個案回報時需依既定倫理、同意與專業協作流程處理，而不是由分析人員單憑 VAF 下結論。

三、從 FASTQ 到候選事件：三條相連但不同的分析路徑



3.1 SNV/indel calling 的核心問題

Caller 要比較「這些讀段可能由真實變異產生」與「可能只是定序、比對或其他背景錯誤」的支持程度。腫瘤不適合只用固定二倍體的 0%、50%、100% 期待來分析，因為混合與亞克隆讓 VAF 可以落在更廣的範圍。

以 Mutect2 為例，它透過局部 haplotype assembly 與 somatic 模型偵測短變異；原始輸出還需交由 FilterMutectCalls 等步驟處理。這是一個工具案例，不代表所有流程都必須使用它。[Mutect2 官方文件](#)

Haplotype 是同一條染色體上相連的 allele 組合；局部組裝嘗試重建候選序列，避免僅逐位點數鹼基而忽略 indel 附近的複雜比對。Likelihood 是在特定模型下觀察到這些資料的相對支持度，不是直接的臨床可信度。

3.2 Calling、filtering、annotation 各自回答不同問題

步驟	問題	常見輸出
Calling	哪些位置有足夠證據成為候選變異？	未篩選 VCF、模型統計
Filtering	哪些候選受污染、方向偏差、germline 等因素影響？	FILTER 標記、篩選統計
Annotation	這個變異落在哪個基因、轉錄本或已知條目？	註解 VCF、表格或 MAF
Review / validation	是否有充分而可重現的技術證據？	人工紀錄、追加實驗結果

例如，Mutect2 的方向性資訊可經 LearnReadOrientationModel 建模，與其他資訊一起供 filtering 使用；污染估計也是獨立的證據來源。不要把跑完 caller 當成完成分析，也不要把所有 FILTER 直接刪掉而失去追蹤原因。

[GATK somatic 流程說明](#)

本課實作聚焦於候選事件的證據稽核，不跑完整 Mutect2、人類基因體 alignment 或 CNV/SV caller。因此，不需要下載大型人類 reference、PoN 或安裝整套 GATK；如果後續要執行完整流程，需要另行準備相容資料、環境及驗證方案。

3.3 VCF、MAF 與 segmentation 檔案

VCF 的 CHROM/POS/REF/ALT 定義事件；FORMAT 後的多個樣本欄位提供各自的證據。讀入前先查樣本名稱，不要假設第一欄一定是 tumor。AD 常按 REF、ALT1、ALT2 排列；DP 與 AD 的納入規則依工具而異；AF 可能是模型估計而非單純 AD 比例。

MAF 在此指 **Mutation Annotation Format**，不是第一堂的 minor allele frequency。它常用於癌症 cohort 的變異註解與摘要；欄位可能包含基因、座標、variant classification 與 tumor sample barcode。它通常不保留 BAM 的完整讀段證據，不能代替 VCF/BAM 做 QC。相同縮寫必須依上下文解讀。

Segmentation 檔將連續區域摘要成區段，包含樣本、染色體、起訖位置及區段值。區段值可能是 log2 copy ratio，也可能是絕對 copy number；先查欄位定義。不要把 0.5 的 log2 ratio 讀成「0.5 個拷貝」。

四、腫瘤資料的品質控制：深度之外還要看什麼？

4.1 FFPE、低輸入量與系統性錯誤

FFPE 是 formalin-fixed paraffin-embedded（福馬林固定石蠟包埋）。DNA 可能片段化、交聯或發生損傷；胞嘧啶脫氨可造成 C>T / 互補方向 G>A 類型的假訊號。但 C>T 本身不等於 artifact，真實腫瘤變異也可能是這個替換。

低輸入量代表起始分子有限。反覆定序同一批 PCR 產物可以增加 read depth，卻未必增加獨立證據。系統性錯誤若存在於模板或特定序列環境中，增加深度甚至會使錯誤看起來更穩定。

證據	要問的問題	不能單獨得出的結論
Depth、ALT count	支持讀段多不多？是否來自足夠獨立分子？	高深度一定真實
Base quality	ALT 鹼基本身品質如何？	品質分數能涵蓋全部前處理損傷
Mapping quality	是否可能對到錯誤區域？	MAPQ 高就沒有 reference 或重複區問題
Strand / orientation	ALT 是否集中在特定方向或 read-pair 類型？	正反方向皆有就等於 duplex 驗證
Read position	ALT 是否只出現在末端或 soft clips 附近？	所有末端變異都是錯誤
Local context	周圍是否為 homopolymer、重複序列或 indel？	熱點資料庫可以消除比對疑慮
Normal evidence	normal 深度、ALT、污染是否足夠評估？	normal 0 reads 證明完全不存在

Soft clipping 是比對中未納入對齊的讀段端部；它可來自接頭、比對困難或真實結構變異。需要看群體一致性與區域背景，不是見到 clipping 就刪除。

4.2 Strand、orientation 與 duplex 不要混用

Read strand 指比對到 reference 的正 / 反向。Paired-end orientation 同時涉及配對、read1/read2 與方向；F1R2/F2R1 不是單純的正股 / 反股計數。

Duplex consensus 需要將原始 DNA 雙股的相應分子證據配對整合。一般 BAM 中正反向都有 ALT，不代表已證明原始同一 DNA 分子的雙股都支持。本課合成 BAM 是 single-end，僅示範 strand 與 read-end bias，不示範 F1R2 或 duplex。

UMI (unique molecular identifier) 是在適當文庫流程中加入的分子標記，協助辨識讀段家族與建立 consensus。Raw depth、unique molecule depth、consensus depth 不可混為一談。UMI 也不能自動解決所有前期損傷、標記碰撞或比對錯誤。

4.3 技術可信度與功能重要性分開評估

Hotspot 表示某位置有已知重複出現或功能相關背景；它能增加研究興趣，不能替代原始證據。反之，沒有人報導的新位置也不必然是假陽性。

多個 caller 都報出同一事件也不是獨立實驗驗證：它們可能共用相同比對與錯誤來源。Orthogonal validation (正交驗證) 是以具有不同限制或原理的方式查核；所選方法的靈敏度必須適合目標 VAF，不能假設任何傳統方法都能確認低頻訊號。

五、VAF、純度、拷貝數與克隆性

5.1 從簡單的混合模型開始

假設正常細胞為二倍體，normal 不帶該 ALT；腫瘤細胞在此區域的總拷貝數一致，且各 allele 的定序機會相同。令：

- p：腫瘤純度，腫瘤細胞在混合模型中的比例。

- f : cancer cell fraction (CCF) , 帶有這個變異的腫瘤細胞比例。
- m : 帶變異腫瘤細胞內的 mutant copy 數。
- C : 此區域每個腫瘤細胞的總 copy number 。

$$\text{預期 VAF} = p \times f \times m / [p \times C + (1 - p) \times 2]$$

分子是混合物中的 ALT 拷貝貢獻；分母是全部 allele 拷貝貢獻。這是用來理解影響因素的簡化模型，不是可以不帶前提地反推每個病人的 CCF。若亞克隆有不同 CN、normal 也帶 ALT、倍體不同或存在比對偏差，就需要更完整的模型。

情境	p	f	m	C	預期 VAF
二倍體、clonal heterozygous	0.6	1	1	2	30%
純度低，但仍是 clonal	0.1	1	1	2	5%
純度 60%，一半癌細胞帶變異	0.6	0.5	1	2	15%
總 CN=6，只有一份 mutant copy	0.2	1	1	6	約 7.14%
總 CN=6，有三份 mutant copy	0.2	1	3	6	約 21.43%

Clonal 指在分析解析度下，多數或全部癌細胞帶有事件；subclonal 指只存在於部分癌細胞。上述例子說明：5% VAF 也可能來自 clonal event，不能自動解讀成「只有 5% 癌細胞有變異」。

練習：若觀察到 VAF=15%，除了「純度 60%、CCF 50%」，還有什麼解釋？在同樣二倍體、單份 ALT 假設下，純度 30%、CCF 100% 也能得到相同數字。單一 VAF 無法同時辨認所有未知量。

5.2 拷貝數改變會被低純度稀釋

在以正常二倍體為基準、假設測量無偏差的例子中：

$$\text{copy ratio} = [p \times C + (1 - p) \times 2] / 2$$

$$\text{log2 ratio} = \log_2(\text{copy ratio})$$

若腫瘤區域 $C=6$ 、 $p=0.2$ ，混合物的平均拷貝貢獻為 2.8，ratio=1.4，log2 ratio 約 0.485。純腫瘤的 $C=6$ 則為 $\log_2(3) \approx 1.585$ 。同一個增益在低純度下看起來較小。

同為腫瘤 $C=6$ ；以下每個 # 約代表 0.1 log2 ratio (示意)

$p=0.2$	#####	0.485
$p=0.6$	#####	1.138
$p=1.0$	#####	1.585

真實 CNV 流程可能以樣本整體或不同倍體基準正規化，不能把上式直接套在所有 segmentation 輸出。Purity/ploidy fitting (純度 / 倍體估計) 會利用全基因體或目標區的 depth、BAF 等資訊共同推估，可能存在多組合理解。

六、實作：建立可回查的腫瘤與正常證據

6.1 準備練習資料

本練習不需要第一堂的輸出。在 Ubuntu / WSL 執行以下 Bash 指令；若專案路徑不同，只修改第一行：

```
cd ~/KCGMH_Course_Series/demos/lesson-02-somatic
python3 generate.py practice01
cd practice01
bash ../prepare.sh
```

practice01 必須是新資料夾；產生器拒絕覆蓋既有資料。若重做，改成 practice02。prepare.sh 重跑會取代同名分析輸出，重要版本應分開保存。

產生器建立 5,000 bp 的人工 contig chrToy、腫瘤 / 正常 SAM、候選 VCF，以及獨立設計的 CN 區段檔。所有 read 位置與候選標記都是人工指定，**不是 aligner 或 somatic caller 的輸出**。真實分子的獨立性、PCR、UMI、paired-end 與 FFPE 化學損傷沒有被模擬。

檔案	用途
reference.fa、.fai	人工 reference 及索引；不可改用 hg19/hg38 開啟本例
tumor.bam、normal.bam 與 .bai	已排序索引、可供 IGV 查看之讀段
candidates.vcf.gz、.tbi	三個人工候選 SNV，含 TUMOR/NORMAL 欄位
candidates.tsv	VCF 查詢結果
tumor.evidence.tsv、normal.evidence.tsv	從 BAM 讀段重新計算的支持證據
copy_number.seg	獨立的 CN 混合模型示意，不是由上述 BAM depth 算出

6.2 理解資料轉換，而不只執行腳本

prepare.sh 先完成下列步驟。你可以在練習資料夾逐行操作，理解輸入與輸出：

```
samtools faidx reference.fa
samtools view -b tumor.sam | samtools sort -o tumor.bam
samtools index tumor.bam
samtools quickcheck -v tumor.bam
samtools flagstat tumor.bam
bcftools query -l candidates.vcf.gz
bcftools view -h candidates.vcf.gz
bcftools query -f '%CHROM\t%POS\t%ID\t%FILTER[\t%SAMPLE:%AD:%DP:%AF]\n' candidates.vcf.gz
```

samtools view -b 轉成 BAM；sort 排序；index 支援區域查詢。quickcheck 主要檢查基本檔案結構，不會證明每條 read 都正確；flagstat 統計比對旗標，不會證明 candidate 可信。

bcftools query -l 顯示樣本名稱；-h 顯示 header。先確認 TUMOR/NORMAL 欄位，再讀各樣本數字。這裡 AF 是產生器指定的比例；真實檔案需依 header 與 caller 文件確認定義。[BCFtools 文件](#)

本例 GT=0/1 是人工表示 REF 與 ALT 同時存在，不能把腫瘤的 0/1 當成「每個腫瘤細胞都是二倍體雜合」。ReviewBias、NormalEvidence 也是教材自訂 FILTER，不是 Mutect2 的正式 filter 名稱。

6.3 直接從讀段核對，不只相信 VCF

```
samtools view tumor.bam | python3 ../audit_reads.py
samtools view normal.bam | python3 ../audit_reads.py
cat tumor.evidence.tsv
cat normal.evidence.tsv
```

audit_reads.py 只支援本例的 150M CIGAR。它排除 unmapped、secondary、QC-fail、duplicate、supplementary flags，並要求 MAPQ≥20、BQ≥20，逐位點計數 T allele。ALT_END5 是 ALT 距任一讀段端部不足 5 個鹼基的數量。這些門檻只為教學；腳本不處理 indel、重疊 read pairs、UMI 或 somatic likelihood，不能取代正式 pileup/caller。

預期的腫瘤輸出：

POS	DEPTH	ALT	VAF	ALT_FORWARD	ALT_REVERSE	ALT_END5
500	400	20	0.05	10	10	0
1500	400	20	0.05	20	0	20
2500	400	200	0.50	100	100	0

正常樣本在 500/1500 各有 200 條讀段、0 ALT；2500 則為 100/200=50%。

請先記錄：哪一個差異被 VAF 隱藏了？答案是 500 與 1500 的方向和讀段位置分布。兩者 DP/AD 完全相同，但 BAM 證據的形狀不同。

6.4 使用 IGV 查看相同證據

IGV (Integrative Genomics Viewer) 能同時顯示 reference、coverage、reads 與候選事件。先依附錄安裝 Windows 桌面版，再開啟練習資料：

1. 選擇 Genomes → Load Genome from File，載入 reference.fa；.fai 保留在同一資料夾。不要選人類 hg38。
2. 使用 File → Load from File 載入 tumor.bam、normal.bam 與 candidates.vcf.gz，索引留在各自檔案旁。
3. 搜尋 chrToy:450–550，觀察 tumor 與 normal 的 coverage 和 ALT 支持。
4. 在 alignment 軌道按右鍵，選擇依 read strand 著色；點選 read 查看方向、MAPQ 與位置。不要只依顏色猜 allele。
5. 移至 chrToy:1450–1550，比較 ALT 是否集中在同方向、接近 read ends；再查看 chrToy:2450–2550 的 normal 支持。
6. 載入 copy_number.seg，查看 chrToy:1–5000 的區段訊號。它來自獨立 CN 模型，不應與本例 BAM coverage 當成同一套 CN 證據。

以上操作依 [IGV reference 載入說明](#) 與 [alignment 操作文件](#) 整理。不同版本選單文字可能略有差異。

IGV 可能為顯示效能 downsample（抽樣顯示）讀段；畫面上可見的 read 數不一定等於完整計數。低頻 ALT 不明顯時，查看 coverage 詳細資訊與 downsampling 設定，並用上面的 BAM 計數確認。IGV 是證據瀏覽工具，不是統計驗證或 caller。

若暫時無法使用 IGV，先利用第 6.3 節的讀段統計完成案例；圖形界面則可在安裝完成後補做。

七、三個候選事件的整合判讀

請為每個事件記錄四欄：「目前決策」、「支持證據」、「缺少的資訊」、「下一步」。可使用的決策是：保留為研究候選、需要正交驗證、技術上可疑、需要更多資料。這些標籤不是臨床報告分級。

7.1 事件 A：5% VAF，有正反向讀段支持

在 chrToy:500，tumor=20/400，normal=0/200；ALT 正反方向各 10，未集中在讀段端部。假設真實研究還提供該位置為已知 hotspot 的 annotation，你會如何決定？

參考解析：相對於事件 B，A 有較一致的技術支持，可保留為後續研究候選，但還不能稱為已驗證的 somatic hotspot。需要確認分子獨立性、區域比對背景、PoN、normal 偵測能力與實際流程的驗證範圍。若結果重要或接近已驗證流程的界線，需規劃適當追加驗證。chrToy 本身沒有真實基因或 hotspot 身分，不應拿去查臨床資料庫。

7.2 事件 B：同樣 5%，但集中在同方向及末端

在 chrToy:1500，tumor=20/400，normal=0/200；20 條 ALT 全為同方向，且全在末端。參考解析：標記為技術上可疑，回查讀段與前處理；可考慮重新製備或其他適切方式確認，但不能只說「C>T 所以一定是 FFPE」。本例只是 FFPE-like 的偏差形狀，沒有真的模擬化學損傷。

比較 A/B 的關鍵不是「20 ALT 是否足夠」，而是這些支持是否可能共用同一種錯誤來源。若單純把 VAF≥5% 寫成保留規則，兩者都會留下。

7.3 事件 C：低純度中的 copy-number gain

copy_number.seg 在 chrToy:3000–4000 顯示 log2 ratio 約 0.485。已知合成模型假設 $p=0.2$ 、腫瘤 $C=6$ 。若不知道模型真值，你能直接把它判為低幅度 gain，或反推一定是六份拷貝嗎？

參考解析：不能僅憑相對 ratio 指定絕對 CN。需核對 purity/ploidy、正規化基準、區段長度、支持區域數、噪音與 BAF。真實資料中「amplification」的操作定義也依研究與方法而異。這裡可以確認模型展示了低純度的稀釋效果，但不是用十個人工 marker 驗證真實 amplification。

7.4 補充對照 D：normal 同樣有 50% VAF

chrToy:2500 在兩個樣本均約 50%。它提供 germline-like 證據，不應只因出現在腫瘤 VCF 就算 somatic。仍需核對正常來源、配對與區域品質；本例的用途是提醒你「候選檔案中的每一列，不都代表癌症特有變異」。

八、CNV、SV 與癌症 cohort 摘要

8.1 CNV：由相對讀深到區段，再到模型

CNV 分析通常先將 coverage 依區域計數，處理 GC、mappability、capture efficiency 等差異，再與正常或參考樣本比較。Segmentation 尋找相鄰區域的共同變化；最後可結合 BAF 與 purity/ploidy 模型，評估 allele-specific CN。

BAF 在此常以 informative heterozygous loci 提供 allele balance 資訊。只有總 copy ratio，不一定能看出 copy-neutral LOH（總拷貝數不變但雜合性喪失）。WES 目標區不連續、捕捉波動較大；不能直接用未校正 depth 比較兩個基因就判定 CNV。

8.2 SV：斷點證據與替代解釋

SV 包括缺失、重複、倒位、易位等。Split read 是一條 read 的不同部分比對到不同位置；discordant read pair 的距離、方向或染色體關係不同於預期。Caller 可整合這些證據、read depth 與局部組裝提出 breakpoint（斷點）候選。

觀察	可能支持	仍需排除
多條 split reads 指向相近位置	一致斷點	重複序列、多重比對、文庫嵌合
多個 pairs 的 mate 在另一染色體	易位候選	系統性 mapping 或文庫問題
區域 depth 下降並伴斷點	缺失候選	捕捉不均、GC 或 reference 差異

本課 single-end 資料沒有這些 paired-end/SV 證據；請勿在 toy BAM 上尋找並不存在的真實結構變異。DNA 的基因重排也不自動證明產生有表現且具功能的 RNA fusion，可能需要 RNA 或其他證據。

8.3 從事件表到 cohort：分母不能消失

做 cohort summary 時，保留 sample ID、事件唯一識別、過濾狀態、有效分析區域與缺失狀態。同一事件若被多個 transcript 註解，不應當成多個獨立變異。

摘要	容易忽略的分母 / 限制
某基因的變異樣本比例	分母應反映該基因可評估的樣本，不是把未覆蓋當陰性
Tumor mutation burden (TMB)	需定義變異集合、有效 Mb、germline/artifact 排除與平台校準
Microsatellite instability (MSI)	需方法與位點模型，不能由幾筆 indel 或高 TMB 直接替代
CNV 頻率	需一致的可評估範圍、純度與事件定義
治療前後 VAF 變化	也受純度、採樣位置、CN 與覆蓋影響，不一定是克隆擴張

液態切片中的 cfDNA（游離 DNA）只有一部分可能來自腫瘤，稱 ctDNA。低比例、分子輸入量及克隆性造血都會影響結果；未偵測到不等於沒有腫瘤變異。這些是分析設計限制，不是單一 VAF 門檻能解決。

九、延伸練習：抽樣能解釋多少，不能解釋多少？

在練習資料夾執行：

```
python3 ../models.py
```

程式只使用 Python 標準函式庫。第一部分重算第五節的 VAF 混合模型；第二部分假設每條 read 相互獨立、真實 ALT 機率为 0.05 且無錯誤，計算至少看到 3 條 ALT 的機率：

```
X ~ Binomial(n, 0.05)
P(X ≥ 3) = 1 - [P(X=0) + P(X=1) + P(X=2)]
```

Depth n	至少 3 條 ALT 的理論機率
30	約 18.78%
100	約 88.17%
400	接近 100%，程式四捨五入顯示 1.000000

這不是臨床 sensitivity 或 limit of detection (LOD)。真實資料有錯誤、分子重複、位置偏差，caller 也不會只用「3 條 ALT」判定。偵測極限需要適當材料、重複實驗與驗證設計；不能用上表直接聲稱「400x 保證測到 5%」。

思考題：事件 B 多定序十倍，能解決原本的末端 / 方向偏差嗎？解析：未必；若反覆放大同一系統性錯誤，更多 reads 不會創造獨立而正確的證據。

十、自我檢核與研究筆記

10.1 先用自己的話回答

1. Tumor-only 加上 PoN，是否等於有 matched normal？
2. 為什麼 VAF=5% 可能是 clonal，而不一定是 subclonal？
3. A/B 同樣 20/400，哪兩項 BAM 證據使判斷不同？
4. 正反向 ALT 都有，能否稱為 duplex consensus？
5. Normal=0/200 能否證明 allele 完全不存在？
6. Copy ratio 與絕對 copy number 的差異是什麼？
7. 為什麼不能把 VCF/MAF 每一列直接當成一個高可信度 somatic event？
8. 為什麼不能把 toy script 成功執行當成臨床流程驗證？

10.2 參考解析

1. 不等於。PoN 是多人的技術背景；matched normal 才是個案本人的參考，但本身仍有侷限。
2. 在二倍體單份 ALT、純度 10% 且全部癌細胞帶變異的模型中，VAF 即為 5%。
3. ALT 的方向與 read-end 分布；B 集中在單方向及端部。
4. 不能。Duplex 需要原始分子雙股的對應證據。
5. 不能。只代表目前讀段中未觀察到，還受抽樣與有效深度影響。
6. Ratio 是相對測量，受基準與混合影響；絕對 CN 需額外模型和證據。
7. 可能含 artifact、germline、低品質、重複 transcript 註解或尚未篩選事件。
8. 本例只有人工讀段與預設候選，未包含真實樣本差異、caller 效能或驗證材料。

10.3 將本課套用到自己的研究

檢查項目	你的筆記 / 待確認事項
Tumor 與 normal 的來源、配對與採樣時間	
檢體處理、DNA 輸入量、純度與批次	
平台、目標區域、reference 與版本	
獨立分子 / UMI / consensus 的定義	
Somatic calling、filtering 與背景資源	
候選事件的 read-level 證據	
CN、purity/ploidy 的假設與不確定性	
未評估區域、排除理由與驗證需求	

建議保留原始候選與篩選後集合、FILTER 原因、人工觀察、工具版本、資料來源及後續決策。將「技術上可信」、「生物學上有興趣」與「足以支持臨床行動」分開紀錄。

十一、名詞速查

名詞	本課用法
Somatic / germline	後天體細胞來源 / 生殖系來源，不是 VAF 高低分類
Matched normal / tumor-only	同人正常參考 / 只有腫瘤資料的分析設計
VAF / CCF	allele 支持比例 / 帶變異的癌細胞比例，兩者不同
Purity / ploidy	腫瘤混合比例 / 染色體組或拷貝數背景
FFPE / artifact	固定包埋檢體 / 技術形成的非真實候選訊號
UMI / consensus	分子識別標記 / 整合同分子讀段所形成的序列
PoN	多份正常資料建立的背景資源
Strand / orientation	比對正反方向 / 包含 read-pair 結構的方向資訊
CNV / SV	拷貝數變化 / 結構變異，部分事件同時屬兩者
Segmentation / BAF	將訊號整合為連續區段 / 相對 allele 訊號或比例資訊
MAF	此處為 Mutation Annotation Format，不是 minor allele frequency
TMB / MSI	腫瘤突變負荷 / 微衛星不穩定，各需合適分析方法
cfDNA / ctDNA	游離 DNA / 其中腫瘤來源的 DNA
Orthogonal validation	用具有不同限制或原理的方法補充驗證

附錄 A：Windows 軟體安裝與課前檢查

A1. 需要哪些工具？

工具	執行位置	用途
WSL2 Ubuntu	Windows 上的 Linux 環境	執行 Bash 與命令列工具
Python 3	Ubuntu	產生資料、核對讀段、計算模型；不需額外 pip 套件
SAMtools	Ubuntu	SAM/BAM 排序、索引與資料讀取
BCFtools	Ubuntu	VCF 格式檢查、壓縮索引與查詢
IGV Desktop	Windows	查看 reference、BAM、VCF、CN 區段

本課不需要 PLINK、R、Conda、Docker 或 GPU。GATK/Mutect2 僅作分析原理案例，不在本次操作中執行，因此不要求安裝。準備環境前確認院內權限；不得為安裝工具繞過資訊安全限制。

A2. 安裝 WSL2 Ubuntu

已完成第一堂安裝者可略過。Windows 11，或符合 Microsoft 簡易安裝需求的 Windows 10，可在系統管理員 PowerShell 執行：

```
wsl --install -d Ubuntu
```

依提示重新開機，開啟 Ubuntu 並設定 Linux 帳號與密碼。密碼輸入時不顯示字元是正常現象。在 PowerShell 檢查：

```
wsl --list --verbose
```

Ubuntu 的 VERSION 應為 2；若為 1，先確認硬體、虛擬化與政策允許，再依實際發行版名稱設定：

```
wsl --set-version Ubuntu 2
```

簡易指令適用 Windows 10 version 2004、build 19041 以上或 Windows 11；作業系統維護狀態與院內規範另行確認。安裝與疑難排解依 [Microsoft 官方文件](#)。

A3. 安裝命令列工具

以下在 **Ubuntu**，不是 PowerShell 執行：

```
sudo apt update
sudo apt install -y python3 samtools bcftools
python3 --version
samtools --version
bcftools --version
```

不需要 `pip install`。Ubuntu 套件版本可能不同於本教材測試環境，請保留版本資訊；需要指定版本時應由研究流程統一管理，而非自行混用多個安裝來源。

A4. 放置完整教材並測試

先在 Windows 解壓完整專案。假設位置是 `C:\Users\你的帳號\Downloads\KCGMH_Cource_Series`，且 Ubuntu 尚未有該資料夾，可在 Ubuntu 執行：

```
cp -r "/mnt/c/Users/你的帳號/Downloads/KCGMH_Cource_Series" ~/KCGMH_Cource_Series
cd ~/KCGMH_Cource_Series/demos/lesson-02-somatic
python3 generate.py preclass01
cd preclass01
bash ../prepare.sh
python3 ../verify.py .
python3 ../models.py
```

請將「你的帳號」換成實際值。若第一堂已複製專案，不要再次執行整個 `cp -r` 而產生巢狀資料夾；先確認第二堂的 `demos/lesson-02-somatic` 已更新進去。`preclass01` 已存在時換一個新名稱。

`verify.py` 應顯示 `PASS`；它核對合成輸出的預期值，不驗證 `somatic caller` 效能。保存版本：

```
python3 --version > versions.txt
samtools --version >> versions.txt
bcftools --version >> versions.txt
```

A5. 安裝 Windows IGV Desktop

1. 開啟 [IGV 官方下載頁](#)，選擇與 Windows / CPU 架構相符的桌面版本。
2. 優先使用包含 Java runtime 的 Windows 安裝包，依安裝程式提示完成。若改用不含 Java 的套件，依當版官方要求安裝相符 Java；目前文件標示自 IGV 2.19.1 起需 Java 21 或以上。
3. 啟動 IGV，確認可開啟本機檔案。記下 Help / About 中的版本供紀錄。
4. 按正文第 6.4 節載入本例 reference 與資料，不需要下載人類全基因體。

如果 Windows IGV 不便直接讀 WSL 路徑，可先在目前的練習資料夾執行 `explorer.exe`，透過檔案總管複製所需檔案至新的 Windows 資料夾。需一起複製 `reference.fa/.fai`、兩份 `.bam/.bam.bai`、`candidates.vcf.gz/.tbi` 與 `copy_number.seg`；不要只複製 BAM 而遺漏索引。

你也可以在 Windows 檔案總管使用 `\\wsl.localhost\Ubuntu\home\你的Linux帳號\...` 找到資料；發行版與帳號依實際環境調整。只使用本課合成檔案；不得將院內病人檔案上傳至未核准網站。

A6. 常見問題

現象	檢查方式
command not found	確認在 Ubuntu，且已完成 apt 安裝
FileExistsError	產生器保護既有資料；改用新練習資料夾
找不到 ../audit_reads.py	確認在 lesson-02-somatic 下產生的練習資料夾
IGV 空白或沒有 chrToy	載入本課 reference，不是人類 reference；縮放到指定座標
IGV 看見的 read 數比 DP 少	可能 downsampling；回查完整 BAM 計數與顯示設定
IGV 找不到索引	BAM/BAI、VCF.gz/TBI 需一起複製並保持相符名稱
Python 說只支援 150M	你可能用了其他資料；本腳本不是通用 pileup 工具
腫瘤與正常顛倒	先查 read group 的 SM 與 VCF 的樣本名稱
沒有管理員權限	洽資訊部門或使用核准環境；可先做表格判讀

附錄 B：實作邊界與延伸閱讀

本教材的 SAM、VCF 與 CN 區段都是人工設計；BAM 證據統計與模型計算會實際執行，但不代表已完成 somatic discovery。IGV 用於視覺核對，與正交驗證不同。欲處理真實資料，需依研究目標選定相容、可重現且經過適當驗證的流程。

- [Mutect2](#)：somatic short-variant calling 的工具案例。
- [GATK somatic workflow](#)：方向性、污染與過濾步驟。
- [BCFtools](#)：VCF 查詢與格式操作。
- [IGV alignment 文件](#)：讀段與 coverage 的顯示限制。
- [IGV paired-end 文件](#)：配對方向與結構變異證據。

文件核對日期：2026-09-13。實際測試環境、驗證內容與未測試項目見[第二堂示範說明](#)。